

**HAVAALANLARI İÇİN DERİN ÖĞRENME
TABANLI KUŞ TESPİT SİSTEMİ**

Onur Can DURUKAN

Hakan HAMİTOĞLU

**HEE 498 Havacılık Elektrik Elektronik
Uygulamaları Dersi Raporu
Havacılık ve Uzay Bilimleri Fakültesi**

Danışman: Doç. Dr Aziz KABA

Eskişehir Teknik Üniversitesi Havacılık ve Uzay Bilimleri Fakültesi
Havacılık Elektrik ve Elektronik Bölümü

06.2024

Bu tez çalışması 1919B012323737 numaralı TÜBİTAK 2209A projesi tarafından desteklenmiştir.

Hakan HAMİTOĞLU ve Onur Can DURUKAN'ın HEE 498 Havacılık Elektrik Elektronik Uygulamaları dersi kapsamında yaptığı “Havaalanları İçin Derin Öğrenme Tabanlı Kuş Tespit Sistemi” başlıklı çalışması 15/06/2024 tarihinde, aşağıdaki jüri tarafından değerlendirilerek başarılı bulunmuştur.

Adı Soyadı

İmza

Danışman : Doç. Dr. Aziz KABA

Üye : Dr. Öğr. Üyesi Kadriye YAMAN

Üye : Prof. Dr. Ebru YAZGAN

ÖZET

Kuş çarpmaları, uçaklar, pilotlar ve yolcular için önemli bir güvenlik tehdidi oluşturmakta olup, yapılan çalışmalara göre her yıl askeri ve ticari havacılık sektörüne uçak kaybı ve hasar, hizmet dışı kalma gecikmeleri ve can kayıpları nedeniyle yıllık 1,21 milyar doların üzerinde maliyet doğurmaktadır. Uluslararası Sivil Havacılık Örgütü (ICAO), verilerine dayanarak 2016-2021 yılları arasında 273.343 kuş çarpma olayının raporlandığını belirtmektedir. Bu tez, kuş çarpmalarının havacılık sektörüne olan etkilerini azaltmaya yönelik yeni bir yaklaşım geliştirmeyi amaçlamaktadır. Bu yaklaşım, mevcut RADAR tabanlı sistemlerin sınırlamalarını ortadan kaldırarak kuşları daha ayrıntılı bir şekilde tespit etmek ve uçuş güvenliğini artırmak için görüntü tabanlı bir kuş tanıma sistemi tasarlamayı hedeflemektedir. Bu tezin özgün değeri, mevcut RADAR sistemlerinin sınırlamalarını aşarak kuşları daha ayrıntılı bir şekilde tespit eden ve tanımlayan bir görüntü tabanlı kuş tanıma sistemi geliştirmektir. Kuş çarpmalarının önlenmesi ve havacılık güvenliğinin artırılması açısından büyük bir öneme sahiptir. Araştırma, YOLOv8 gibi nesne tanıma modellerini kullanarak kuşları tespit etmek ve türlerini belirlemek için bir görüntü tabanlı sistem geliştirmeyi içermektedir. YOLOv8 görüntüyü tek bir geçişte analiz ederek hızlı çalışma özelliğine sahiptir, bu da çarpışmalardan kaçınmada daha hızlı tepki süreleri sağlar. Bu modellerin kullanımı, hafiflik, etkililik ve hız açısından avantajlar sunarak verimli bir kuş tanıma ve çarpışma uyarı sistemi oluşturmayı amaçlar. Veri toplama, veri hazırlığı ve ön işleme, derin öğrenme tabanlı model eğitimi, entegrasyon ve performans iyileştirmesi aşamalarından bulunmaktadır. Bu tez yardımıyla havacılık sektöründeki kuş çarpmalarının maliyetini azaltma ve uçuş güvenliğini artırma potansiyeli taşımaktadır. Geliştirilecek olan görüntü tabanlı sistem, RADAR sistemleri ile bir araya getirilerek, kuş çarpmalarının önlenmesi veya azaltılması için kullanılabilir. Ayrıca, RADAR sistemleriyle bu yeni sistem entegre edilerek RADAR üzerinden bir uzaklık bilgisi ve bu proje sayesinde de tanımlanan kuşların türünü öğrenerek bir zarar tahmini ve daha detaylı bir ikaz sistemi geliştirilebilecektir.

Anahtar Kelimeler: Derin Öğrenme, YOLOv8, Kuş Çarpması, Havacılık Güvenliği

İÇİNDEKİLER

ÖZET	iii
ŞEKİLLER DİZİNİ.....	vii
TABLolar DİZİNİ.....	viii
1. GİRİŞ.....	1
1.1. Türkiye’de Sivil Havacılık	2
1.2. Sivil Havacılıkta Güvenlik	4
1.3. Sivil Havacılıkta Kuş Çarpması olayı	6
1.3.1. Kuş Çarpması Raporları.....	6
1.3.2. IBIS Analizi.....	6
1.3.3. Örnek Olaylar	7
1.4. RADAR Tabanlı Sistemler	13
2. YAPAY ZEKA İLE YAKLAŞIM.....	16
2.1. Yapay Zeka ve Kuş Çarpması	19
2.2. Yapay Zeka Mimarileri.....	19
2.2.1 Konvolüsyonel Sinir Ağları (CNN).....	20
2.2.2. CNN’nin Mimari Yapısı ve Çalışma Prensipleri	21
2.2.3. CNN’nin Avantajları.....	21
2.3. Yapay Mimarilerin Karşılaştırılması: MobilNet ve YOLO	22
2.4. YOLO Kullanmanın Sebepleri	23
3. YOLO (YOU ONLY LOOK ONCE).....	24
3.1. YOLO'nun Temel Özellikleri	24
3.2. Gelişmiş YOLO Sürümleri ve Uygulama Alanları	24
3.2.1 YOLOv5.....	25
3.2.2. YOLOv5'in Özellikleri	25
3.3. YOLOv8: Gelişmiş Nesne Tespit Teknolojisi.....	25
3.3.1 YOLOv8'in Mimarisi.....	25
3.3.2. YOLOv8'in Öne Çıkan Özellikleri.....	26
3.3.3. YOLOv8'in Alt Modelleri ve Nano Modelinin Seçimi	27
3.3.4. YOLOv8'in Havacılık Sektöründeki Kullanımı	28
3.3.5 CUDA kullanımı	28
3.4. PyTorch Kütüphanesi	28

3.4.1. PyTorch'un Temel Modülleri	29
3.4.2. PyTorch'un Avantajları	29
3.4.3. PyTorch'un YOLOv8 ile Entegrasyonu	30
3.5. Roboflow.....	30
4. VERİ SETİ OLUŞTURMA	32
4.1. Roboflow Üzerinde Veri Seti Oluşturma	32
4.1.1. Proje Oluşturma.....	33
4.1.2. Veri Seti Yükleme	34
4.1.3. Görsellerin Etiketlenmesi.....	35
4.1.4. Veri Setinin İyileştirilmesi	36
4.2. Roboflow Üzerinden Veri Setinin Dışarı Aktarılması.....	40
4.2.1. Dışa Aktarım Formatının Belirlenmesi	40
4.2.2. Veri Setinin Eğitim, Doğrulama ve Test İçin Bölünmesi	40
4.2.3. Veri Setinin İndirilmesi.....	41
5. MODELİN EĞİTİMİ.....	42
5.1. Gerekli Ortamın Hazırlanması.....	42
5.2. Veri Setinin Eğitime Hazırlanması	43
5.3. Model Eğitime Başlanması	44
5.3.1. Eğitim Sürecinin İzlenmesi.....	45
5.4. Modelin Kullanımı.....	46
5.4.1. Modelimiz Üzerinden Alınan Tahmin Sonuçları.....	46
6. DERİN ÖĞRENME MODEL PERFORMANSI	49
6.1. Karışıklık Matrisi.....	49
6.1.1. Modelimizin Karışıklık Matrisi Çıktısının Değerlendirmesi	50
6.2. Kesinlik Eğrisi (Precision Curve)	51
6.2.1. Modelimizin Doğruluk Çıktısının Değerlendirmesi	52
6.3. Duyarlılık Eğrisi (Recall Curve)	53
6.3.1. Modelimizin Duyarlılık Çıktısının Değerlendirmesi.....	54
6.4. Doğruluk-Duyarlılık Eğrisi (PR-Curve)	55
6.4.1. Modelimizin Kesinlik-Duyarlılık Çıktısının Değerlendirmesi	56
6.5. F1 Skoru ve Eğrisi	57
6.5.1. Modelimizin F1 Eğrisi Çıktısının Değerlendirmesi	58

6.6. Etiketler (Labels) ve Dağılımları	59
6.7. Modelin Genel Sonuçları ve Değerlendirilmesi	60
6.8. Kayıplar	61
6.8.1.Eğitim (Train) Kayıp Değerleri	61
6.8.2. Doğrulama (Validation) Kayıp Değerleri	62
6.8.3. Performans Metrikleri	62
SONUÇ	64
KAYNAKLAR	65

ŞEKİLLER DİZİNİ

Şekil 1 Uçak Trafiği (2016-2023)	2
Şekil 2 2019-2022 ACC trafik ve değişim verileri	3
Şekil 3 Yolcu Trafiği (2016-2023)	3
Şekil 4 Uçak kazaları yüzdeleri	5
Şekil 5 Hudson Nehri olayı	7
Şekil 6 DL-2295 acil iniş.....	8
Şekil 7 NK-3044 reject takeoff	9
Şekil 8 Kuş çarpması yapısal hasar örneği.....	10
Şekil 9 Rapor edilen hasar, uçuş esnası negatif durum, AoG durumu, tamir masrafı ve diğer giderler.....	11
Şekil 10 ICAO kuş çarpması raporu	12
Şekil 11 2001-2021 kuş çarpması olayı karakteristikleri	12
Şekil 12 Kuş tespit RADAR'ı	13
Şekil 13 Temel RADAR çalışma mantığı.....	14
Şekil 14 YOLO kuş tespiti.....	18
Şekil 15 Roboflow arayüzü.....	33
Şekil 16 Roboflow kullanımı.....	33
Şekil 17 Roboflow üzerinden veri seti oluşturma	34
Şekil 18 Görsel etiketleme işlemi.....	35
Şekil 19 Etiketlenen görsel	35
Şekil 20 Örnek veri seti	36
Şekil 21 Veri seti iyileştirmesi (augmentation)	37
Şekil 22 Augmentation çeşitleri	38
Şekil 23 Veri setinin dışarı aktarımı.....	40
Şekil 24 Model tahmini 1	46
Şekil 25 Model tahmini 2	47
Şekil 26 Model tahmini 3	47
Şekil 27 Model tahmini 4	48
Şekil 28 Karışıklık Matrisi	50
Şekil 29 Doğruluk eğrisi	52
Şekil 30 Duyarlılık Eğrisi	54
Şekil 31 Kesinlik-Duyarlılık Eğrisi.....	56
Şekil 32 F1 eğrisi	58
Şekil 33 Etiket dağılımı verileri.....	60
Şekil 34 Modelin genel sonuçları ve değerlendirmesi	60

TABLÖLAR DİZİNİ

Tablo 1 Mobilnet ve YOLO farkı20

Tablo 2 Confusion matrix çıktısı anlamı49

KISALTMALAR DİZİNİ

YOLO	: You Only Look Once
RADAR	: Radio Detection and Ranging
GSYİH	: Gayrisafi Yurtiçi Hasıla
ICAO	: International Civil Aviation Organisation
FAA	: Federal Aviation Administration
SHGM	: Sivil Havacılık Genel Müdürlüğü
PW	: Pratt & Whitney
ATC	: Air Traffic Controller
ReLU	: Rectified Linear Unit
CNN	: Convolutional Neural Network
CUDA	: Compute Unified Device Architecture
CPU	: Central Process Unit
GPU	: Graphics Processing Unit
API	: Application Programming Interface
CuDNN	: CUDA Deep Neural Network
PR	: Precision-Recall
NMS	: Non-Maximum Suppression
AoG	: Aircraft on Ground

1. GİRİŞ

Modern dünyanın en hızlı ve güvenilir ulaşım yöntemlerinden biri olan havacılık; ülkelerin ekonomik, sosyal ve kültürel uygulamalarında büyük bir rol oynamaktadır. 20. yüzyılın başlarında teknolojik bir yenilik olarak ortaya çıkan havacılık, 1903 yılında Wright Kardeşler 'in ilk başarılı uçuşunu gerçekleştirmesiyle ivme kazanmayı başarmıştır. Bu önemli adımla beraber, yolcudan kargoya, lojistikten turizme, küresel ticaretten kültürel değişime kadar pek çok alanda görüş ve ekonomilere ciddi katkılar sağlayan bir sektöre dönüşmüştür. Günlük sivil havacılık bölümü, sadece Amerika Birleşik Devletinde yılda yaklaşık 900 milyon yolcu taşıyarak ülkenin toplam GSYİH'sine 1,5 dolar katkı sağlarken, dünya genelinde 4,5 milyar yolcunun değişimi ile seyahat artışı mümkün kılınmaktadır.

İleri teknoloji gerektiren ve sınır tanımaz özelliğe sahip havacılık endüstrisinde ülkemiz, uluslararası havacılık gelişmelerini yakından takip etmek ve çağın gereklerini yerine getirmek için çeşitli uluslararası teşkilatlara üye olmuştur. Uluslararası Sivil Havacılığın temelini oluşturan "Uluslararası Sivil Havacılık Anlaşması" Şikago Sözleşmesi'ne ülkemiz 1945 yılında taraf olmuş ve Uluslararası Sivil Havacılık Teşkilatı-ICAO kurucu üyeleri arasında yer almıştır. Ayrıca, Avrupa bölgesinde ise Avrupa Sivil Havacılık Konferansı- ECAC'a 1956 yılında kurucu üye olan ülkemiz, Avrupa Seyrüsefer Emniyeti Teşkilatı EUROCONTROL'e de üye durumdadır. Ayrıca bölgesel düzeyde de çeşitli organizasyonlara üye olan ülkemiz, Havacılık faaliyetlerini ulusal ve uluslararası mevzuata uygun olarak kararlılıkla sürdürmektedir.

2023 yılı boyunca Türkiye'deki uçak şebekesi ve sivil uçuşların görülmeyeceği değerde bir artış görülüyor. Türkiye genelindeki sivil uçuşlar yılda yaklaşık 1,68 milyon kez gerçekleştirilmekte olup, bu sayı 2022'ye kıyasla %13'lük bir artış ifade etmektedir. Ayrıca, Türkiye'nin havacılık sektöründe öne çıkan İstanbul Havalimanı, günlük ortalama 1.156 uçuşla Avrupa'nın yoğun havalimanlarından biri olmuştur. Ankara Saha Kontrol Merkezi (ACC) de Avrupa'da uzaklık açısından 4. sırada yer almakta ve yılda yaklaşık 1,27 milyon uçuşa hizmet vermektedir.

Türkiye'deki toplam uçak sayısı 2022 itibarıyla yaklaşık 570 olup, bu rakam Türkiye'nin faaliyet sektöründeki büyüme potansiyelini de göstermektedir. Bu gelişmeler, Türkiye'nin havacılık sektöründeki güçlü ve özellikle bölgesel merkez olarak konumlanmasını sağlıyor.

1.1. Türkiye’de Sivil Havacılık

Türkiye’de sivil havacılığın temelleri, Mustafa Kemal Atatürk’ün "İstikbal göklerde" vizyonu ile 1925 yılında kurulan Türk Tayyare Cemiyeti ile atılmıştır. Bu vizyon, Türkiye’nin havacılık alanındaki gelişmelere öncülük etmesini sağlamıştır. 1933 yılında "Türk Hava Postaları" adıyla başlayan ilk sivil hava taşımacılığı girişimi, Cumhuriyetin 10. yılında Millî Savunma Bakanlığı’na bağlı Havayolları Devlet İşletme İdaresi’ne devredilerek kurumsal bir yapıya kavuşmuştur. Günümüz havacılık endüstrisinde ülkemiz, uluslararası havacılık gelişmelerini yakından takip etmek ve çağın gereklerini yerine getirmek için uluslararası sivil havacılık alanında da önemli adımlar atmış ve 1945 yılında Uluslararası Sivil Havacılık Anlaşması’na (Şikago Sözleşmesi) taraf olarak Uluslararası Sivil Havacılık Teşkilatı (ICAO) kurucu üyeleri arasında yer almıştır. Bunun yanı sıra Avrupa bölgesinde de etkili bir şekilde yer alarak, 1956 yılında Avrupa Sivil Havacılık Konferansı’na (ECAC) ve Avrupa Seyrüsefer Emniyeti Teşkilatı’na (EUROCONTROL) üye olmuştur.


2023 yılı boyunca Türkiye genelinde 1,68 milyon uçuş gerçekleştirilmiş ve bu sayı, 2022 yılına kıyasla %13’lük bir artışı ifade etmiştir. Bu büyüme, sivil havacılık sektörünün dinamizmini ve büyüme potansiyelini gözler önüne sermektedir. İstanbul Havalimanı, günlük ortalama 1.156 uçuşla Avrupa’nın en yoğun havalimanlarından biri olarak uluslararası havacılık sahnesinde lider konumunu pekiştirmiştir. Bu başarısı ile İstanbul Havalimanı, yalnızca Türkiye’nin değil, aynı zamanda bölgenin havacılık merkezi olma yolundaki kararlılığını kanıtlamıştır. Şekil 1’de Türkiye’nin yıllara göre gerçekleştirdiği uçuş miktarları bulunmaktadır.

	2016	2017	2018	2019	2020	2021	2022	2023
Toplam Uçak Trafığı	1.452.995	1.500.457	1.544.169	1.556.417	853.750	1.204.618	1.488.626	1.685.877
İç Hat	886.228	909.332	892.405	839.894	572.994	738.352	786.150	869.404
Dış Hat	566.767	591.125	651.764	716.523	280.756	466.266	702.476	816.473

Şekil 1 Uçak Trafığı (2016-2023)

Türkiye'nin havacılık sektöründeki başarıları sadece havalimanlarıyla sınırlı kalmamaktadır. Ankara Saha Kontrol Merkezi (ACC), Avrupa'da toplam uçuş kontrol mesafesi açısından 4. sırada yer almış ve yılda yaklaşık 1,27 milyon uçuşa hizmet vermiştir. Bu veri, Türkiye'nin sadece havalimanlarıyla değil, aynı zamanda hava trafik kontrolünde de yüksek standartlara sahip olduğunu göstermektedir.

Ankara Saha Kontrol Merkezi (ACC) 2022 yılı içinde ortalama 1 milyon 273 bin uçuşa hizmet vererek en yoğun 4. ACC olmuştur. Şekil 2'de Ankara dahil diğer ACC yoğunlukları verilmiştir.



Şekil 2 2019-2022 ACC trafik ve değişim verileri

948 bin uçuş ile Avrupa'da en yoğun iniş/kalkış yönetimine sahip ülkeler arasında 6. sırada yer almıştır.

Yolcu taşımacılığındaki veriler de sivil havacılığın önemini vurgulamaktadır. 2023 yılında Türkiye genelindeki havalimanlarında toplam 214 milyonu aşkın yolcu seyahat etmiştir. Bu yolcuların 91 milyonu iç hatlarda, 123 milyonu ise dış hatlarda seyahat etmiş; yolcu sayısı bir önceki yıla göre iç hatlarda %16, dış hatlarda ise %19 oranında artmıştır. Yıllara göre grafiği Şekil 3'te gösterilmiştir.


	2016	2017	2018	2019	2020	2021	2022	2023
Toplam Yolcu Trafik (direkt transit dahil)	174.153.146	193.576.844	210.947.639	208.911.338	81.703.685	128.350.222	182.225.531	214.136.575
Toplam Yolcu Trafik	173.743.537	193.045.343	210.498.164	208.373.696	81.616.140	128.155.762	181.789.339	213.693.163
İç Hat	102.499.358	109.511.390	112.911.108	99.946.572	49.740.303	68.466.177	78.323.824	90.390.766
Dış Hat	71.244.179	83.533.953	97.587.056	108.427.124	31.875.837	59.689.585	103.465.515	123.302.397
Direkt Transit Yolcu	409.609	531.501	449.475	537.642	87.545	194.460	436.192	443.412

Şekil 3 Yolcu Trafik (2016-2023)

1.2. Sivil Havacılıkta Güvenlik

Havacılık güvenliği, sektördeki ilerlemelere rağmen en büyük görünürlüğe devam etmektedir. 2023 yılı takvimlerine göre, dünya çapındaki uçak kazalarının büyük kısmı, uçakların yerden yakın kalkışları ve kalkış sırasında gerçekleşmektedir. Kazaların bu anlarda yoğunlaşmasının yaygın nedenleri arasında pilotaj hataları, teknik arızalar ve hava koşulları yer almaktadır. Türkiye ve dünya genelindeki kaza verilerinin listesi, iniş ve kalkış sırasında yaşanan olayların güvenlik protokolleri ve eğitimdeki eksikliklere işaret edildiği görülmektedir.

Tüm bu veriler, sivil havacılık sektörünün yalnızca ekonomik ve stratejik önemini değil, aynı zamanda güvenliğin sektördeki vazgeçilmez yerini de gözler önüne sermektedir. Havacılıkta, yolcuların, mürettebatın ve uçakların güvenli bir şekilde uçuşlarını tamamlaması birincil önceliktir. Bu doğrultuda, uluslararası standartlara uyum sağlamak, teknolojik yeniliklerden faydalanmak ve sıkı denetim mekanizmalarını uygulamak büyük bir gerekliliktir. Hava trafiğinin yoğun olduğu İstanbul Havalimanı gibi merkezlerde entegre sistemlerle süreçlerin izlenmesi ve kontrol edilmesi, güvenliği artıran temel unsurlar arasında yer almaktadır. Güvenliğin üst düzeyde tutulması, yalnızca bireysel emniyeti sağlamakla kalmaz, aynı zamanda sivil havacılık sektörünün sürdürülebilir büyümesine ve küresel rekabet gücünün korunmasına da katkı sağlar. Bu nedenle, havacılık sektöründe güvenlik her zaman öncelikli bir sorumluluk olarak ele alınmaktadır. Uçak kazaların sebepleri yüzdesel olarak Şekil 4'te gösterilmektedir.



Şekil 4 Uçak kazaları yüzdeleri

Güvenlik her zaman öncelikli bir sorumluluk olarak ele alınmasına rağmen, elde olan ya da olmayan nedenlerle bazı kazalar yaşanabilmektedir. Havacılık sektöründeki kazaların nedenleri arasında insan hataları, teknik arızalar, hava koşulları gibi faktörler yer alırken, çevresel etkenler de önemli bir rol oynamaktadır. Verilere göre, kazaların %54'ü pilot hatalarından kaynaklanmaktadır. Bu oran, pilotların eğitim seviyeleri, karar verme süreçleri ve operasyonel baskıların azaltılması konusundaki çalışmaların ne kadar önemli olduğunu vurgulamaktadır. Teknik arızalar, uçak sistemlerinde yaşanan mekanik veya elektronik sorunlardan kaynaklanmakta olup, kazaların %21'inden sorumlu tutulmaktadır. Çevresel faktörler, özellikle kötü hava koşulları gibi öngörülemeyen durumlar, %12'lik bir paya sahiptir. Ayrıca, kuş çarpması (bird strike) gibi olaylar kazaların %5'ini, bakım eksiklikleri %6'sını ve hava trafik kontrol hataları ise %2'sini oluşturmaktadır.

Bu istatistikler, havacılık kazalarının farklı nedenlerle meydana geldiğini ve her bir faktöre yönelik kapsamlı ve bütüncül bir yaklaşım geliştirilmesi gerektiğini ortaya koymaktadır. İnsan hatalarının azaltılması için pilot eğitime ve simülasyon tabanlı karar destek sistemlerine yatırım yapılması önem arz ederken, teknik arızaların önlenmesi için uçak bakım standartlarının

daha da iyileştirilmesi gerekmektedir. Çevresel faktörler için ise hava trafik kontrol sistemlerinin modernize edilmesi ve ileri hava durumu tahmin teknolojilerinin kullanılması büyük önem taşır.

1.3. Sivil Havacılıkta Kuş Çarpması olayı

1.3.1. Kuş Çarpması Raporları

FAA, ABD'deki kuş çarpması olaylarını kayıt altına alır ve raporlar yayımlar. Bu raporlar, olayların frekansı, yerleri ve etkileri hakkında bilgi sağlar.

FAA'nın Wildlife Strike Database, kuş çarpmaları ile ilgili verileri içerir ve analizler sunar.

EASA, Avrupa'daki kuş çarpması olaylarını izler ve raporlar. Bu raporlar, hava yolu şirketleri ve havaalanları için önemli bilgiler içerir.

ICAO, küresel düzeyde kuş çarpması olaylarını izler ve raporlar. Bu raporlar, uluslararası havacılık güvenliği standartlarının geliştirilmesine katkıda bulunur.

SHGM Türkiye içinde veya Türk havacılık firmalarına bağlı uçuşlarda meydana gelen kuş çarpması olaylarını kaydeder ve raporlar.

Kuş çarpması, özellikle iniş ve kalkış sırasında meydana gelen kazaların önemli bir nedenidir. Kalkış sırasında uçaklar alçak irtifada seyir halindeyken kuş sürüleriyle karşılaşma olasılığı oldukça yüksektir. Federal Havacılık İdaresi (FAA) sistemlerine göre, dünya genelinde ortalama olarak yılda 13.000 kuş çarpması durumu rapor edilmektedir. Bu kazaların ekonomik maliyeti milyarlarca doları bulurken, uçuş güvenliğinde ciddi riskler ortaya çıkmaktadır. Türkiye de bu sorundan etkilenmektedir.

1.3.2. IBIS Analizi

Uluslararası Sivil Havacılık Örgütü (ICAO), kendilerinin Kuş Çarpması Bilgilendirme Sistemi (IBIS) verilerine dayanarak 2016-2021 yılları arasında 273.343 kuş çarpma olayının raporlandığını belirtmektedir. Bu veriler, önceki yıllarla karşılaştırıldığında, kuş çarpmalarının zaman içinde artan bir hızla gerçekleştiğini göstermektedir. Bu durum, uçuş güvenliği açısından ciddi bir endişeye yol açmakla kalmayıp, aynı zamanda doğal yaşamı da olumsuz yönde etkilemektedir. Dolayısıyla, kuş çarpmalarının azaltılması veya önlenmesi hem havacılık sektörü hem de doğal çevre açısından büyük öneme sahiptir.

1.3.3. Örnek Olaylar



Şekil 5 Hudson Nehri olayı

Kuş çarpmaları, her ne kadar toplam havacılık kazalarının %5'ini oluşturuyor gibi görünse de uçuş güvenliği açısından kritik bir öneme sahiptir. Küresel verilere göre, dünya genelinde her yıl yaklaşık 13.000 kuş çarpması vakası rapor edilmektedir ve bu olayların yaklaşık %65'i uçakların kalkış veya iniş sırasında meydana gelmektedir. Özellikle kalkış ve iniş sırasında yaşanan bu tür olaylar, uçuş güvenliğini doğrudan tehdit etmektedir. Bu çarpışmalar, uçak motorlarında ciddi hasarlara yol açabilir ve operasyonel aksamalara sebep olabilir. Örneğin, 2009 yılında US Airways Flight 1549, kalkıştan kısa bir süre sonra bir kuş sürüsüne çarparak her iki motorunu da kaybetti. Pilot Chesley "Sully" Sullenberger, uçağı Hudson Nehri'ne başarılı bir şekilde indirdi ve tüm yolcular kurtuldu. Şekil 5, Hudson Nehri'nden çekilmiş bir fotoğraftır. Bir diğer kaza ise, 19 Kasım 2022'de Delta Airlines'a ait bir Airbus A320 (N330NW), Atlanta'dan Omaha'ya yapılacak iç hatlar yolcu uçuşu DL2295 sırasında gece, bulutsuz havada ve 290 knot hızla, Omaha'daki varış noktasına doğru 13.000 feet'in altına inerken, kuş çarpması sonucu patlayıcı bir dekompresyon meydana geldi. Acil durum ilan edildi ve uçuş, başka bir olay yaşanmadan belirlenen varış noktasına tamamlandı. Uçuşun inişinden sonra yapılan dış incelemede, gövde kaplamasında üç farklı yerde kırılmalar tespit edildi. Yapısal hasar önemli derecede değerlendirildi ve uçak, büyük onarımlar için hizmetten çekildi. Söz konusu kuşlar, DNA analiziyle göç eden Kar veya Ross Kazları olarak tanımlandı;

bunlardan ilki 2,6 kg'a kadar ağırlığa sahip olabilir. Uçuşun güvenliği tehlikeye girmemiş olsada hava aracı önemli bir yapısal hasar aldı. Şekil 6'da oluşan yapısal hasar görülmektedir.



Şekil 6 DL-2295 acil iniş

Bir Spirit Airlines Airbus A320-200N, kayıt numarası N922NK olan, NK-3044 uçuşunu gerçekleştiren Atlantic City, NJ-e Fort Lauderdale, FL (ABD) 105 yolcu ve 7 mürettebatla, mürettebat düşük hızda kalkışı reddettiğinde Atlantic City'nin pist 31'inden kalkış için hızlanıyordu yaklaşık 60 deniz miline ulaşınca sağ motorda (PW1127G) bir kuş çarpması yaşadı. Hemen ardından uçak güvenli bir şekilde yavaşladı ve pistin yaklaşık 550 metre / 1800 fit aşağısındaki pistte durdu, kule uçağın yardıma ihtiyacı olup olmadığını sorguladı, mürettebat acil durum belirtti. Kısa bir süre sonra kule, motorun altında yangın çıktığını bildirdi. Yangının oluşturduğu hasar Şekil 7'de gösterilmiştir. Mürettebat, bu iletimin arka planında yangın zilin

duyulduğunu kabul etti ve yaklaşık bir dakika sonra uçağı tahliye etmelerini tavsiye etti. Yolcu olarak seyahat eden 3 yolcu ve 1 mürettebat tahliye sonucu hafif yaralandı



Şekil 7 NK-3044 reject takeoff

31 Temmuz 2012'de, Continental Airlines'a ait bir Boeing 737-900, Denver'a gündüz iniş yapmak üzere alçalırken ve yaklaşık 6000 fit yükseklikten geçerken tek bir büyük kuşa çarptı ve radome, bir pitot kafası ve dikey dengeleyici hasar gördü. Uçuş ekibi acil durum ilan etti ve ATC yardımıyla yaklaşmaya devam ederek sorunsuz bir iniş gerçekleştirdi. Olaya karışan kuş daha sonra, normalde yaklaşık 500 gr ağırlığında olan ancak istisnai olarak 700 gr ağırlığa ulaşabilen bir tür olan White Faced Ibis olarak tanımlandı. Radome'da açılan delik 60 cm x 30 cm idi. Radome bölgesinde oluşan hasar Şekil 8'de görünmektedir.



Şekil 8 Kuş çarpması yapısal hasar örneği


Bu örnekler, kuş çarpmalarının hem uçuş güvenliği hem de operasyonel sürdürülebilirlik açısından ne denli ciddi tehditler oluşturabileceğini açıkça göstermektedir. Hudson Nehri'ne acil inişi, büyük bir felaketten dönülmesini sağlamış, ancak kuş çarpmalarının motorlar üzerinde yaratabileceği hasarın ciddiyetini ortaya koymuştur. Benzer şekilde, 2022'de Omaha'da meydana gelen patlayıcı dekompresyon, büyük yapısal hasarın yanı sıra göçmen kazların uçaklar için oluşturabileceği riski vurgulamaktadır.

Kuş çarpmaları yalnızca güvenlik açısından değil, aynı zamanda ekonomik etkileriyle de havacılık sektöründe önemli bir sorun teşkil etmektedir. Küresel havacılık sektörüne her yıl 2 milyar doların üzerinde maliyet yükleyen bu olaylar, uçaklarda ciddi yapısal hasarlara ve operasyonel aksamalara yol açmaktadır. Havayolları, kuş çarpmaları nedeniyle yılda yaklaşık 1,2 milyar dolarlık operasyonel maliyetle karşı karşıya kalmakta ve bu durum uçuş gecikmeleri ile iptallere neden olmaktadır. Maaliyet ve AoG durumları için verilen raporların sonuçları Şekil 9'da gösterilmektedir.

Year	Number of reports indicating:					Mean losses per report ²		
	Dam-age	NEOF	Aircraft down time	Repair costs	Other costs	Down-time (hours)	Repair costs (\$)	Other costs (\$)
1990	372	144	60	33	16	56.4	268,342	77,031
1991	400	176	61	49	25	79.8	91,006	49,056
1992	365	207	81	51	28	111.9	130,234	6,553
1993	399	229	67	57	19	277.9	110,635	11,678
1994	459	259	103	73	29	388.4	95,231	113,720
1995	498	296	95	62	33	96.3	626,556	273,528
1996	503	336	143	86	39	138.2	105,015	31,425
1997	575	362	182	126	47	230.7	94,666	49,553
1998	588	384	205	135	54	119.5	249,493	35,573
1999	705	409	282	179	79	148.8	137,271	26,003
2000	765	445	350	205	93	193.6	122,035	142,102
2001	648	411	294	157	65	143.5	353,044	48,425
2002	669	437	383	165	63	135.6	188,528	79,657
2003	630	407	352	171	81	107.1	199,774	53,068
2004	630	394	324	213	92	166.9	130,681	28,210
2005	609	379	327	227	125	88.0	331,897	95,613
2006	603	371	334	172	102	116.5	266,168	16,552
2007	568	395	364	178	135	165.2	214,159	41,229
2008	527	346	371	156	141	116.2	146,507	17,403
2009	608	466	561	194	192	73.9	467,184	18,068
2010	603	412	526	174	164	66.5	161,525	17,162
2011	547	441	526	180	208	70.8	296,747	18,791
2012	626	444	689	228	263	75.4	136,823	10,495
2013	616	453	802	238	304	75.7	81,178	15,487
2014	592	504	718	210	277	63.2	173,408	13,254
2015	624	497	705	208	293	50.0	188,624	24,149
2016	598	492	577	151	223	63.7	84,786	15,156
2017	680	538	628	190	265	35.7	221,272	15,340
2018	724	586	633	168	297	53.3	73,580	9,713
2019	766	598	709	160	249	28.0	129,562	24,755
2020	491	443	482	113	189	37.9	122,827	9,540
2021	667	450	617	147	224	60.1	271,871	18,031
2022	700	593	640	116	177	40.9	188,887	92,199
2023	709	720	852	138	270	34.0	220,125	29,492
Total	20,064	14,024	14,043	5110	4,861	1,168,417²	999,306,144²	147,677,886²
Mean	590	412	413	150	143	83.2	195,559	30,380

Şekil 9 Rapor edilen hasar, uçuş esnası negatif durum, AoG durumu, tamir masrafı ve diğer giderler

Uluslararası havacılık otoriteleri, kuş çarpmalarının etkilerini en aza indirmek için bu olayları izlemekte ve raporlamaktadır. ABD Federal Havacılık İdaresi (FAA), Wildlife Strike Database aracılığıyla ABD'deki kuş çarpması olaylarını kayıt altına alarak detaylı analizler sunmaktadır. Avrupa Havacılık Emniyeti Ajansı (EASA) ise Avrupa'daki kuş çarpmalarını izleyerek bölgesel düzeyde önlemler geliştirilmesine katkı sağlamaktadır. Küresel düzeyde ise Uluslararası Sivil Havacılık Örgütü (ICAO), IBIS (Kuş Çarpması Bilgilendirme Sistemi) ile kuş çarpmalarını analiz etmekte ve üye ülkelere önerilerde bulunmaktadır. ICAO IBIS verilerine göre, 2016-2021 yılları arasında dünya genelinde 273.343 kuş çarpması olayı rapor edilmiştir. Türkiye özelinde, Sivil Havacılık Genel Müdürlüğü (SHGM) verileri, 2023 yılında Türkiye'deki havalimanlarında 570'ten fazla kuş çarpması olayı bildirildiğini göstermektedir. Bu durum, Türkiye'nin de bu küresel sorundan etkilendiğini ve önlem alması gerektiğini açıkça ortaya koymaktadır. Şekil 10 ve Şekil 11, ICAO'nun yayınladığı, 'wildlife strike' raporlarının miktarıdır.



Şekil 10 ICAO kuş çarpması raporu

Data	2001-2007	2008-2015	2016-2021
States reporting	51	91	136
States/territories of occurrence	145	105	194
Strikes reported	42 508	97 751	273 343
Day time strikes	63%	68%	68%
Night time strikes	24%	25%	19%
Peak month activity	12% (August)	14% (August)	12% (July and August)
Strikes during takeoff	39%	31%	24%
Strikes during approach	37%	33%	23%
Strikes during landing	17%	25%	23%
Wildlife specie most frequent	Perching birds	Perching birds	Hawks, eagles and vultures
Part struck most frequent	Engines and Radome	Engines and Radome	Engines and Radome
Part damage most frequent	Engines and Wing/Rotor	Engines and Wing/Rotor	Engines and Wing/Rotor

Şekil 11 2001-2021 kuş çarpması olayı karakteristikleri

1.4. RADAR Tabanlı Sistemler


Uluslararası havacılık otoritelerinin kuş çarpması olaylarını izleme ve raporlama çalışmaları, bu küresel sorunun önlenmesine yönelik alınacak önlemler için önemli bir temel oluşturmaktadır. Türkiye de bu konuda proaktif adımlar atmış ve özellikle İstanbul Havalimanı gibi büyük havalimanlarında, Şekil 12’de görüldüğü gibi RADAR tabanlı kuş izleme sistemleri, lazer ve sesli caydırıcı teknolojilerle entegre çözümler geliştirmiştir. Bu teknolojiler, havalimanlarının çevresinde kuş hareketlerini izleyerek erken tespit ve uyarı mekanizmaları ile kalkış ve iniş gibi kritik uçuş aşamalarında riskleri azaltmayı hedeflemektedir.



Şekil 12 Kuş tespit RADAR’ı

RADAR sistemleri elektromanyetik dalgalar gönderir ve bu dalgalar havadaki cisimlere çarptığında yansıyor ve geri döner. Kuşlar, boyutlarına ve hareketlerine bağlı olarak bu dalgaları yansıtır. Kuşların yansıtma alanı (RADAR çapraz kesiti), RADAR sinyallerinin algılama kapasitesi açısından önemlidir. Kuşların kanat çırpışları ve hareketleri RADAR’a farklı bir sinyal verir. Kuşlar, rüzgarla hareket etme eğilimindedir; bu da RADAR’la tespitlerinde belirgin bir örüntü sağlar. Böcekler gibi diğer küçük cisimlerden farklı olarak, kuşlar çoğunlukla rüzgarın etkisi altında kalmadan belirli bir yön ve hızla ilerleyebilir. RADAR sinyalleri kuşların hız ve yönünü belirleyerek, onları diğer nesnelerden (örneğin uçaklar, böcekler) ayırt edebilir. RADAR, kuşların uçuş yüksekliğini ve süratini ölçebilir. Kuşlar genellikle belirli bir hız ve

yükseklikle hareket ederler, bu da onları farklı sınıflara ayırmayı sağlar (örneğin, göç eden kuşlar genellikle daha yüksek irtifalarda uçarken, yerel kuşlar daha alçak irtifalarda hareket eder). Kuşlar sürü halinde veya bireysel olarak RADAR sinyallerinde belirli bir hareket deseni oluşturur. Sürüler halinde uçan kuşlar, RADAR ekranında kümelenme şeklinde görünür. RADAR verilerinde, belirli aralıklarla düzenli hareket eden nesneler genellikle kuşlara işaret eder, çünkü kuşlar belirli aralıklarla kanat çırpır. Böceklerin aksine, kuşlar rüzgar yönünün aksine uçabilir. Bu yüzden RADAR sinyallerinde rüzgar yönünden farklı yönde hareket eden nesneler genellikle kuş olarak değerlendirilir. Rüzgar yönü ile kuşların yönü karşılaştırılarak, RADAR hedeflerinin kuş olup olmadığı hakkında daha doğru bir tahminde bulunulabilir. Şekil 13'te RADAR'ın temel çalışma mantığı gösterilmiştir.



Şekil 13 Temel RADAR çalışma mantığı

RADAR tabanlı kuş izleme sistemleri, bird strike (kuş çarpması) riskini azaltmada etkili bir çözüm olarak öne çıkmasına rağmen, bazı önemli dezavantajlara sahiptir. İlk olarak, bu sistemlerin kurulumu, bakımı ve işletilmesi oldukça yüksek maliyetlidir. Bu durum, özellikle sınırlı bütçeye sahip küçük ve orta ölçekli havalimanları için önemli bir engel teşkil edebilir. Ayrıca, RADAR'lar genellikle büyük kuşları ve sürüleri tespit etmede etkili olsada, küçük kuşların algılanmasında yetersiz kalabilir. Bu eksiklik, özellikle motorlarda hasara yol açabilecek küçük kuşların erken tespit edilmesini zorlaştırmaktadır. RADAR tabanlı sistemlerin bir diğer dezavantajı, bazen kuş olmayan nesneleri (örneğin, havadaki diğer objeler veya hareketli yer nesneleri) yanlışlıkla kuş olarak algılamasıdır. Bu durum, gereksiz alarmlar oluşturabilir ve operasyonel gecikmelere yol açabilir. Yoğun yağmur, kar veya sis gibi kötü hava koşulları da RADAR'ların performansını olumsuz etkileyebilir, bu da kuş hareketlerini doğru bir şekilde izlemeyi zorlaştırmaktadır. Ayrıca, RADAR sistemleri büyük miktarda veri üretmektedir ve bu verilerin analiz edilmesi, karar süreçlerine entegre edilmesi için uzman ekip

ve gelişmiş yazılım desteği gerektirir. Bu süreç hem zaman alıcı hem de operasyonel açıdan karmaşık bir yapı oluşturabilir. Yapılan analizlere göre, RADAR tabanlı kuş izleme sistemlerinin kullanımı, kuş çarpması olaylarını %20 oranında azaltmayı başarmıştır. Bu sistemler, havalimanı çevresindeki kuş hareketlerini sürekli izlerken, potansiyel tehditleri önceden tespit ederek uçuş ekiplerini zamanında bilgilendirmekte ve caydırıcı sistemleri otomatik olarak devreye sokmaktadır. Özellikle yoğun hava trafiğine sahip İstanbul Havalimanı gibi merkezlerde, bu teknolojilerin uygulanması sayesinde kuş çarpmalarından kaynaklanan ciddi kazaların sıklığı önemli ölçüde azalmış, uçuş operasyonlarının güvenliği ve verimliliği artırılmıştır.

RADAR tabanlı kuş izleme sistemleri, kuş çarpmalarının önlenmesinde önemli bir adım olarak görülmekte ve yapılan analizlere göre bu sistemlerin kullanımı kuş çarpması olaylarını %20 oranında azaltmayı başarmıştır. Ancak, uçuş güvenliği gibi hata toleransının olmadığı kritik bir alanda bu başarı oranı tek başına yeterli değildir. Kuş çarpmaları, kalkış ve iniş gibi operasyonel açıdan hassas uçuş anlarında uçuş ekipleri ve yolcular için ciddi güvenlik riskleri oluşturmakla birlikte, havacılık sektörüne ekonomik ve operasyonel anlamda büyük zararlar vermektedir. Her yıl milyarlarca dolarlık mali kayba ve uçuş gecikmelerine neden olan bu olayların tamamen önlenmesi, havacılık güvenliği açısından hayati bir gerekliliktir. RADAR tabanlı sistemler, geniş bir alanı tarayarak büyük kuş sürülerini algılayabilme yeteneğine sahip olsa da küçük kuşların tespit edilmesindeki yetersizlik, yanlış alarmlar, kötü hava koşullarındaki performans kaybı, yüksek enerji tüketimi ve sınırlı detay sunma kapasitesi gibi önemli eksikliklere sahiptir. Bu sistemler yalnızca kuşların genel hareketlerini algılayabilirken, kuş türleri, renkleri, boyutları ve sayıları gibi ayrıntılı bilgileri sağlayamamaktadır. Bu durum, alınacak önlemlerin yeterince spesifik ve etkili olmasını engelleyerek uçuş güvenliğinde sınırlı bir katkı sunmaktadır. Ayrıca, RADAR sistemleri yüksek maliyetli olup taşınabilirliği zordur ve ürettikleri büyük miktardaki verinin analiz edilmesi uzun zaman alarak operasyonel karmaşıklığa yol açmaktadır. 1 boyutlu veri sağlayan RADAR sistemlerinin aksine, 3 boyutlu çalışan görüntü tabanlı sistemler, kuş türlerini daha hassas bir şekilde tanımlayarak daha detaylı ve etkili çözümler sunmaktadır. %20 oranında bir azalma, mevcut teknolojiyle elde edilmiş önemli bir başarı olarak değerlendirilse de uçuş güvenliği gibi kritik bir alanda bu oran yeterli değildir. Tüm bu nedenler, RADAR sistemleri yerine görüntü tabanlı yapay zekâ ve derin öğrenme teknolojileri gibi yenilikçi bir yaklaşıma geçilmesi gerektiğini açıkça ortaya koymaktadır.

2. YAPAY ZEKA İLE YAKLAŞIM

İnsan beyni, sayısal işlemleri hızlı bir şekilde gerçekleştirebilmenin yanı sıra anlama, yorumlama, karar verme gibi kompleks görevleri de son derece kısa sürede gerçekleştirme yeteneğine sahiptir. Örneğin, yolda yürüyen bir insan, yürüyüş alanındaki engelleri ve tehlikeleri matematiksel olarak hesaplamasa da, geçmişteki deneyimlerine ve öğrenilmiş bilgilerine dayanarak yürüme hızını ve yönünü seçebilir. Buna karşılık, bilgisayarlar karmaşık sayısal işlemleri son derece hızlı bir şekilde gerçekleştirebilse de, olayları yorumlama, öğrenme, karar verme ve deneyimlerden elde edilen bilgileri kullanma yeteneklerinden yoksundur. Bu fark, insan beyninin üstünlüğünü, deneyim ve sınıflandırılmış veriyi kullanabilme kabiliyetinden alır.

Bu noktada yapay zeka devreye girmektedir. Yapay zeka, insan zekasına özgü idrak ve öğrenme yeteneklerini modellemeyi ve bu yetenekleri bilgisayar sistemlerine kazandırmayı amaçlayan bir teknolojidir. İnsan davranışlarını ve düşünce süreçlerini taklit ederek, bilgisayarlara problemlere çözüm üretebilme, anlamlandırma, genelleme yapabilme ve geçmiş deneyimlerden öğrenme gibi yetenekler kazandırmayı hedefler. Bir başka deyişle, yapay zeka, bilgisayar veya bilgisayar destekli bir makinenin genellikle insana özgü olan çözüm üretme, anlam çıkarma, genelleme ve öğrenme gibi yüksek mantık süreçlerini gerçekleştirme yeteneği olarak tanımlanır (Nabiyev, 2012).

Yapay zekanın temelinde öğrenme becerisi yatmaktadır. Nasıl ki insanlar bir işi öğrenmeden etkili bir şekilde gerçekleştiremiyorsa, yapay zekanın da benzer şekilde öncelikle belirli bir görevi öğrenmesi gereklidir. Yapay zekanın en büyük katkılarından biri, öğrendiği bilgiyi en doğru çözüm yolunu bulmak için hızlı bir şekilde uygulayabilmesidir. Bu öğrenme süreci, yapay zekanın temelini oluşturan makine öğrenmesi ve derin öğrenme algoritmaları sayesinde gerçekleşir.


Makine öğrenmesi, büyük veri setleri üzerinde çalışarak girdi ve çıktılar arasındaki ilişkileri analiz eder ve bu verilerden gelecekteki olaylara yönelik tahminler yapar. Derin öğrenme, yapay zekanın bir alt dalı olup insan beyninin çalışma prensiplerinden esinlenerek geliştirilmiş çok katmanlı bir öğrenme modelidir. Derin öğrenme algoritmaları, yapay sinir ağlarını kullanarak verilerden özellikleri otomatik olarak çıkarır, farklı seviyelerde soyutlama yaparak daha doğru ve kapsamlı sonuçlar elde eder. Bu teknoloji, özellikle görüntü tanıma, doğal dil işleme, ses tanıma ve otonom sistemler gibi karmaşık problemlerde yüksek başarı oranlarıyla dikkat çeker.

Derin öğrenmenin en büyük avantajlarından biri, veri miktarı arttıkça performansının da artmasıdır; bu da büyük veri çaığında derin öğrenmeyi en güçlü araçlardan biri haline getirmiştir.

Yapay zekanın önemli özelliklerinden biri, öğrendiği bilgileri genelleleyebilmesi ve yeni durumlara hızlı bir şekilde uyum sağlayabilmesidir. Bu yetenek, özellikle sürekli değişen ve belirsizlik içeren sistemlerde büyük avantajlar sunar. Örneğin, bir yapay zeka sistemi, belirli bir kuş türünü tanımlamayı öğrendikten sonra benzer özelliklere sahip diğer kuş türlerini de tanıyabilir ve bu bilgiyi çeşitli uygulamalarda etkili bir şekilde kullanabilir.

Bunun yanı sıra, yapay zeka sistemleri, insan faktörüne bağlı dikkat dağınıklığı veya duygusal etkiler gibi sınırlamalardan bağımsız çalışarak daha tutarlı ve güvenilir kararlar alabilme yeteneğine sahiptir. Büyük veri setlerini hızlı bir şekilde analiz edebilmesi, insanların aylarca sürebilecek çalışmalarını saniyeler içinde tamamlamasına olanak tanır. Bu özellikler, sağlık, finans, havacılık ve üretim gibi birçok sektörde yapay zekanın etkinliğini ve önemini artırmaktadır. Yapay zeka, yalnızca bir teknolojik araç olmanın ötesine geçerek, modern dünyanın karmaşık problemlerine çözüm sunan güçlü bir teknoloji haline gelmiştir.

Özellikle makine öğrenmesi ve derin öğrenme algoritmaları, verilerden anlam çıkarma ve doğru tahminlerde bulunma konusunda büyük bir devrim yaratmıştır. Bu bağlamda, derin öğrenmenin en güçlü mimarilerinden biri olan Konvolüsyonel Sinir Ağları (CNN), özellikle görüntü işleme ve nesne tanıma gibi alanlarda çığır açıcı bir çözüm olarak dikkat çekmektedir. CNN'nin sunduğu yüksek doğruluk ve hızlı işlem kapasitesi, özellikle kuş tanıma ve uçuş güvenliğini artırmaya yönelik uygulamalarda büyük bir potansiyel taşımaktadır.



Şekil 14 YOLO kuş tespiti

Bu tezde, mevcut RADAR sistemlerinin dezavantajlarını aşmak amacıyla yapay zekâ ve derin öğrenme tabanlı bir kuş tanıma sistemi geliştirilmesi önerilmektedir. Geliştirilecek bu sistem, kameralar aracılığıyla elde edilen kuş görüntülerini analiz ederek, kuş türlerini ve hareketlerini gerçek zamanlı olarak tespit edecektir. Yapay zekâ algoritmalarının, kameradan gelen verileri işleyerek risk teşkil eden kuş türlerini ve davranışlarını doğru bir şekilde analiz edebileceği düşünülmektedir. Bu yaklaşım, yalnızca küçük kuşları algılamadaki yetersizlik sorununu çözmekle kalmayacak, aynı zamanda yanlış alarmları en aza indirerek operasyonel verimliliği artıracaktır.

Görüntü tabanlı yapay zekâ sistemleri, RADAR sistemlerine kıyasla daha fazla ayrıntı sağlayarak kuşların tam konumunu, türünü, boyutlarını ve renklerini doğru bir şekilde tanımlayabilir. Ayrıca, düşük enerji tüketimi ve kolay taşınabilirlik gibi avantajları sayesinde RADAR tabanlı sistemlere kıyasla daha sürdürülebilir ve maliyet etkin bir çözüm sunmaktadır. Bu sistemler, kötü hava koşullarında çalışabilirlikleri ve yüksek doğruluk oranları ile uçuş güvenliğini artırmak için ideal bir alternatif oluşturmaktadır. Tüm bu nedenlerle, bu tezde RADAR yerine yapay zeka ve derin öğrenme tabanlı bir sistem geliştirilmesi üzerine odaklanılmıştır. Bu sistemin, mevcut RADAR tabanlı yaklaşımlara kıyasla hem teknik hem de operasyonel açıdan üstün bir çözüm sunacağına inanılmaktadır.

2.1. Yapay Zeka ve Kuş Çarpması

Yapılan araştırmalar sonucu mevcut geliştirilen sistemlerin genel olarak RADAR temelli olduğu fark edilmiştir. RADAR çalışma mesafesi ve hava koşullarından etkilenme gibi durumlarda avantajlı olsa da kuşların tam konumunu, sayısını, tahmini boylarını, renklerini ve türlerini tespit etmekte başarılı değildir ayrıca bunları yaparken yüksek miktarda güç tüketimi vardır ve taşınabilirliği zordur. Ek olarak 3 boyutlu çalışan görüntü sistemlerinin aksine RADAR sistemi 1 boyutludur. Görüntü temelli bir sistem kuşlar hakkında daha detaylı veri vermekle birlikte taşınması kolaydır ve güç tüketimi daha düşüktür. Günümüzde araştırmalar, temel bir soru üzerine odaklanmaktadır: "Kuş çarpmalarını azaltmak için görüntü tabanlı bir kuş tanıma sistemi nasıl geliştirilebilir?" Bu temel soru altında aşağıdaki hipotezler veya çalışma soruları da ele alınabilir: Görüntü tabanlı bir kuş tanıma sistemi, mevcut RADAR sistemlerine göre kuşları daha ayrıntılı bir şekilde tespit edebileceğine inanılmaktadır.

2.2. Yapay Zeka Mimarileri

YOLOv8 ve MobilNetV2 gibi nesne tanıma modelleri, kuş türlerini belirlemede başarılıdır. Geliştirilen görüntü tabanlı sistemin havacılık sektöründe kuş çarpmalarını önleme veya azaltma konusunda büyük atılımlar yapabileceği öngörülmüyor. MobilNet ve YOLO, bilgisayarla görme alanında popüler olan, nesne tespiti ve sınıflandırmada kullanılan iki farklı derin öğrenme mimarisidir. İkisi de farklı amaçlar için optimize edilmiş olsada, her ikisi de nesne tespiti için oldukça etkilidir.

MobilNet, daha çok sınıflandırma ve özellik çıkarımı için tasarlanmış, hafif ve verimli bir sinir ağıdır. Mobil cihazlarda ve gömülü sistemlerde hızlı çalışacak şekilde optimize edilmiştir. Özellikle sınırlı donanımsal kaynaklarda çalışmak için idealdir.

Çekirdek olarak hafif bir yapı kullanır ve bu sayede yüksek performanslı donanıma ihtiyaç duymadan çalışabilir. Özellikle mobil cihazlar gibi sınırlı işlem gücüne sahip ortamlarda yüksek hız sunar, ancak nesne tespiti doğruluğu YOLO kadar yüksek değildir.

Sınıflandırma ve temel nesne tespiti görevlerinde yeterli doğruluk sağlar, ancak YOLO kadar hassas değildir. Nesneleri sınıflandırmakta başarılı olsa da, küçük nesneler ya da karmaşık sahnelerde YOLO'ya kıyasla daha düşük doğruluğa sahip olabilir.

Hafif bir modeldir, bu yüzden mobil cihazlarda veya sınırlı donanım kaynaklarına sahip cihazlarda çalışmak için idealdir. MobilNet'in düşük sayıda parametreye sahip olması, model boyutunu küçük tutarak hızlı çalışmasını sağlar.

YOLO, nesne tespiti için geliştirilmiş bir mimaridir ve yüksek doğrulukla nesnelerin yerini belirler. YOLO, aynı anda birden fazla nesne tespit edebilmesi ve hızlı çalışması sayesinde gerçek zamanlı uygulamalarda popülerdir.

YOLO, nesne tespiti için özel olarak optimize edilmiştir ve oldukça hızlı çalışır. YOLO mimarisinin yeni sürümleri (YOLOv4, YOLOv5, YOLOv7 gibi) daha hızlı ve daha doğru hale getirilmiştir, bu da gerçek zamanlı tespitlerde kullanımı ideal kılar. Ancak MobilNet'e göre daha fazla hesaplama gücüne ihtiyaç duyar.

Yüksek doğruluk sunar ve tek bir geçişte nesnelerin konumlarını ve sınıflarını belirler. Özellikle YOLO'nun yeni versiyonları, daha karmaşık sahnelerde bile yüksek doğrulukla çalışır. YOLO, küçük nesnelerin algılanmasında ve çeşitli nesneleri tespit etmede MobilNet'ten daha başarılıdır.

YOLO modelleri genellikle daha büyüktür ve daha fazla hesaplama kaynağına ihtiyaç duyar. Ancak, YOLO'nun 'Tiny' gibi daha hafif versiyonları da geliştirilmiştir; bu versiyonlar düşük güç tüketimi gerektiren uygulamalarda kullanılabilir. Sonuç olarak genel bakış Tablo 1'de görüldüğü gibidir.

Özellik	Mobilnet	YOLO
Kullanım Amacı	Yüksek (düşük kaynaklarda)	Çok yüksek (doğru donanımda)
Doğruluk	Yeterli, sınırlı doğruluk	Yüksek doğruluk
Model Boyu	Küçük, hafif	Büyük ('tiny' versiyonu hafif)
Uygulama Alanları	Mobil uygulamalar, gömülü sistemler	Otonom araçlar, güvenlik, dronlar

Tablo 1 Mobilnet ve YOLO farkı

Sonuç olarak havacılık sektöründe kuş tespiti için makine öğrenmesine dayalı gerçek zamanlı bir yapay zeka mimarisi seçiminde YOLO'nun daha etkili bir yaklaşım olduğu görülür.

2.2.1 Konvolüsyonel Sinir Ağları (CNN)

Yapay zekânın öğrenme ve genelleme becerileri, teknolojiyi yalnızca bir araç olmaktan çıkararak karmaşık sorunlara çözüm üretebilen yenilikçi bir teknoloji haline getirmiştir. Bu alanda, özellikle derin öğrenme algoritmaları sayesinde önemli ilerlemeler kaydedilmiş, bu algoritmalar arasında Konvolüsyonel Sinir Ağları (CNN) öne çıkmıştır. CNN, insan beyninin görme sisteminden ilham alınarak geliştirilmiş bir derin öğrenme mimarisi olup, özellikle görüntü işleme, nesne tespiti ve sınıflandırma gibi görevlerde çığır açıcı başarılar elde etmiştir.

2.2.2. CNN'nin Mimari Yapısı ve Çalışma Prensibi

CNN, katmanlar halinde çalışan bir yapıya sahiptir ve verilerden özellik çıkararak bu özellikleri sınıflandırma veya tahmin yapmak için kullanır. Mimari, genellikle dört ana yapıdan oluşur:

- **Evrişim Katmanı (Convolution Layer):** Bu katman, giriş verisi üzerinde belirli filtreler (kernels) kullanarak önemli özellikleri çıkarır. Görüntüdeki kenarlar, dokular ve desenler gibi yerel özellikleri tanımlar ve bir özellik haritası (feature map) oluşturur. Böylece görüntüdeki uzamsal ilişkiler korunarak detaylı analiz yapılır.
- **Havuzlama Katmanı (Pooling Layer):** Havuzlama katmanı, görüntü verisinin boyutunu küçülterek modelin daha verimli çalışmasını sağlar. En yaygın kullanılan havuzlama yöntemi Maksimum Havuzlama (Max Pooling) olup, belirli bir bölgede en yüksek değeri seçerek önemli bilgilerin kaybolmasını önler ve hesaplama yükünü azaltır.
- **Tam Bağlantılı Katman (Fully Connected Layer):** Bu katman, evrişim ve havuzlama katmanlarından gelen özellikleri alarak nihai sınıflandırmayı gerçekleştirir. Sinir ağlarının öğrenme yeteneğini kullanarak veriyi anlamlandırır ve doğru sonuçlar üretir.
- **Aktivasyon Fonksiyonu (Activation Function):** Doğrusal olmayan dönüşümler yaparak daha karmaşık ilişkileri öğrenme yeteneği sağlar. Genellikle ReLU aktivasyon fonksiyonu kullanılır ve bu, modelin doğruluk oranını artırır.

2.2.3. CNN'nin Avantajları

CNN, geleneksel görüntü işleme yöntemlerinden farklı olarak, görüntülerden özellikleri otomatik olarak öğrenir ve çıkarır. Bu, manuel özellik mühendisliği ihtiyacını ortadan kaldırarak zamandan tasarruf sağlar. Ayrıca CNN'nin parametre paylaşımı ve yerel bağlantıları, hesaplama maliyetini azaltırken geniş veri setlerinde yüksek performans elde edilmesini mümkün kılar. Bu özellikleri sayesinde CNN, yüz tanıma, tıbbi görüntü analizi, otonom sürüş ve nesne tanıma gibi birçok uygulamada üstün başarı göstermiştir.

CNN'nin havacılık güvenliğinde uygulanması, görüntü işleme ve analizinde devrim yaratan bir teknoloji olarak derin öğrenmenin en etkili mimarilerinden biridir. Karmaşık verilerle çalışırken sağladığı yüksek doğruluk ve hız, modern dünyanın ihtiyaçlarına uygun çözümler sunmaktadır. Bu bağlamda, kuş çarpması risklerini azaltmak için CNN tabanlı bir yapay zeka sistemi geliştirilmesi önerilmektedir.

Önerilen sistem, kameralar aracılığıyla elde edilen görüntülerden özellikler çıkararak kuş türlerini sınıflandıracak ve potansiyel riskleri gerçek zamanlı olarak değerlendirecektir.

CNN'nin, küçük kuşları ve diğer riskli türleri hassas bir şekilde tespit edebilme yeteneği sayesinde, risk teşkil eden durumlarda ikaz sistemleri ve caydırıcı önlemler otomatik olarak devreye sokulacaktır. Bu yaklaşım, RADAR tabanlı sistemlerin küçük kuşları algılamadaki yetersizlik sorununu çözmekle kalmayacak, aynı zamanda yanlış alarmları en aza indirerek operasyonel verimliliği artıracaktır.

Ayrıca, CNN tabanlı bu sistem, kötü hava koşullarında bile etkin bir şekilde çalışarak daha hassas ve doğru bir tespit mekanizması sunacaktır. Kamera tabanlı yapay zeka sistemleri, yüksek doğruluk oranları, maliyet etkinliği ve taşınabilirliği sayesinde mevcut RADAR sistemlerinin yerini alarak uçuş güvenliğini artırmak için daha optimal bir çözüm sağlayacaktır. Bu durum, CNN'nin görüntü işleme alanındaki üstünlüklerinin havacılık güvenliği gibi kritik bir alanda etkili bir şekilde kullanılabileceğini göstermektedir.

2.3. Yapay Mimarilerin Karşılaştırılması: MobilNet ve YOLO

CNN'in görüntü işleme ve nesne tespitindeki başarısı, çeşitli derin öğrenme mimarilerinin geliştirilmesine ilham kaynağı olmuştur. Bu bağlamda, kuş çarpmalarını önlemek amacıyla tasarlanan yapay zeka tabanlı kuş tespit sistemi, nesne tanıma ve sınıflandırmada öne çıkan MobilNet ve YOLO gibi derin öğrenme modellerinden faydalanmaktadır. Her iki mimari de farklı amaçlar için optimize edilmiş olsa da, nesne tespiti için oldukça etkili araçlardır. Ancak kullanılacak ortamın gereksinimleri ve hedeflenen doğruluk oranı, doğru yapay zeka mimarisinin seçiminde kritik bir rol oynamaktadır.

MobilNet, hafif ve verimli bir alternatif. MobilNet, sınırlı donanımsal kaynaklara sahip cihazlar için geliştirilmiş, hafif ve enerji verimli bir derin öğrenme mimarisidir. Mobil cihazlar ve gömülü sistemler için tasarlanan bu model, sınıflandırma ve temel nesne tespiti görevlerinde yüksek hız ve düşük gecikme süreleri sunar. Küçük model boyutu ve optimize edilmiş yapısı sayesinde, düşük işlem kapasitesine sahip sistemlerde bile hızlı çalışabilir ve enerji tasarrufu sağlayarak uzun süreli işlemler için avantaj sunar.

Ancak, MobilNet'in avantajları, havacılık sektöründe kuş çarpmalarını önlemeye yönelik geliştirilmesi planlanan sistemin gereksinimlerini karşılamada yetersiz kalmaktadır. Kuş tespiti sistemi, özellikle küçük kuş türlerini ve karmaşık uçuş hareketlerini yüksek doğrulukla algılamayı gerektirir. MobilNet, küçük nesnelerin tespiti ve karmaşık sahnelerde hassas analiz yapma konularında sınırlı doğruluğa sahiptir. Bu nedenle, MobilNet, kritik uygulamalarda gerekli performansı sağlayamamakta ve sistemin ihtiyaçlarına uygun bir çözüm sunmamaktadır.

YOLO, gerçek zamanlı ve yüksek doğruluk. YOLO (You Only Look Once), gerçek zamanlı nesne tespiti için optimize edilmiş güçlü bir derin öğrenme mimarisidir. YOLO'nun temel özelliği, nesnelerin hem konumlarını hem de sınıflarını aynı anda tespit edebilmesi ve bunu yüksek doğrulukla gerçekleştirmesidir. Özellikle küçük nesnelerin algılanması ve karmaşık sahnelerde üstün performans göstermesi, YOLO'yu kritik sektörlerde tercih edilen bir model haline getirmiştir. Ayrıca, hızlı işlem kapasitesi sayesinde gerçek zamanlı tespit yeteneği sunar ve birden fazla nesneyi doğru bir şekilde algılayarak kapsamlı analizler yapabilir.

Geliştirilecek kuş tespit sistemi, kuş çarpmalarını önlemek için küçük kuşların hassas bir şekilde algılanmasını ve hızlı tepki verilmesini gerektirmektedir. YOLO, bu gereksinimleri karşılayacak özelliklere sahiptir. Nesne algılama kapasitesi ve gerçek zamanlı çalışma yeteneği sayesinde, kuş hareketlerini anında analiz ederek risk teşkil eden durumlarda ikaz sistemlerini devreye sokabilir. Ayrıca, YOLO'nun küçük nesneleri algılama başarısı ve çoklu nesne tespiti özelliği, havacılık sektöründe uçuş güvenliği için gereken yüksek doğruluk ve hız ihtiyaçlarını etkin bir şekilde karşılamaktadır.

2.4. YOLO Kullanmanın Sebepleri

MobilNet'in düşük donanım gereksinimleri ve enerji verimliliği, mobil cihazlar ve sınırlı işlem gücüne sahip sistemlerde avantaj sağlasa da, kuş çarpmalarını önlemeye yönelik kritik uygulamalarda yeterli performansı sunamamaktadır. YOLO ise, yüksek doğruluk oranı, küçük nesnelerin hassas tespiti ve gerçek zamanlı çalışma kapasitesiyle, geliştirilmekte olan sistemin tüm ihtiyaçlarını karşılayan bir çözüm sunmaktadır. Bu özellikleriyle YOLO, hem hız hem de doğruluk açısından havacılık güvenliği için ideal bir mimari olarak öne çıkmaktadır.

Sonuç olarak, CNN tabanlı yapay zeka sistemleri, YOLO gibi güçlü derin öğrenme mimarilerinin kullanımıyla daha etkin hale getirilebilir. Bu mimariler, RADAR tabanlı sistemlerin eksikliklerini gidermekle kalmayacak, aynı zamanda uçuş güvenliğini artırarak havacılık sektöründe yenilikçi çözümler sunacaktır. Buna karşın YOLO, nesnelerin hem konumlarını hem de sınıflarını yüksek doğrulukla tespit edebilme kabiliyeti sayesinde sistemin ihtiyaçlarına daha uygun bir çözüm sunmaktadır. YOLO, gerçek zamanlı tespit yeteneği ile kuş hareketlerini anında analiz edebilir ve riskli durumlarda ikaz sistemlerini hızlıca devreye sokabilir. Ayrıca, küçük nesnelerin algılanmasındaki üstün başarısı ve çok nesne tespit edebilme kapasitesi, YOLO'yu kuş tespiti sisteminde ideal bir seçim haline getirmektedir. Bu özellikleriyle YOLO, geliştirilmekte olan sistemin yüksek doğruluk, hız ve etkinlik gereksinimlerini karşılayarak havacılık güvenliği için daha uygun bir mimari sunmaktadır.

3. YOLO (YOU ONLY LOOK ONCE)

3.1. YOLO'nun Temel Özellikleri

YOLO (You Only Look Once), nesne tespiti için kullanılan güçlü bir derin öğrenme algoritmasıdır. Görüntüyü tek bir geçişte işleyerek nesnelerin hem konumlarını (bounding box) hem de sınıflarını hızlı ve doğru bir şekilde tespit eder. YOLO, giriş olarak aldığı bir görüntüyü sabit boyutlu bir $S \times S$ ızgaraya böler ve her bir ızgara hücresi, merkez noktası o hücrede bulunan nesnelerin algılanmasından sorumludur. Algoritma, her hücre için bir vektör çıktısı üretir. Bu vektör, şu bilgileri içerir: P_c (hücrede nesne bulunma olasılığı), B_x ve B_y (nesnenin merkez koordinatları), B_w ve B_h (nesnenin genişliği ve yüksekliği) ve $C_1, C_2, \dots, C_n$ (nesnenin hangi sınıfa ait olduğuna dair olasılıklar). Eğer bir hücrede nesne yoksa, $P_c=0$ olur ve diğer parametrelerin bir önemi kalmaz. YOLO, her bir ızgara hücresi için birden fazla bounding box tahmini yapar ve bu kutuların güven skorlarını hesaplar. Güven skoru, bir hücrenin gerçekten bir nesne içerip içermediğine dair olasılığı ($Pr(obj)$) ile tahmin edilen kutunun doğruluğunu ifade eden Intersection over Union (IoU) değerinin çarpımıyla elde edilir.

Bir nesne için birden fazla sınır kutusu tahmin edilebileceğinden, gereksiz kutuların kaldırılması için Non-Maximum Suppression (NMS) algoritması kullanılır. NMS, en yüksek güven skoruna sahip olan kutuyu seçerek diğerlerini eler ve daha doğru sonuçlar elde edilmesini sağlar. YOLO, bu işlemleri tek bir geçişte gerçekleştirerek hız ve doğruluk arasında mükemmel bir denge kurar. Bu özellik, YOLO'yu nesne tespitinde hızlı ve etkili bir çözüm haline getirir.

3.2. Gelişmiş YOLO Sürümleri ve Uygulama Alanları

YOLO algoritması, başlangıcından itibaren sürekli geliştirilerek daha hassas ve verimli hale getirilmiştir. YOLOv5, optimize edilmiş bileşenler ve mimarisi sayesinde genel nesne tespitinde yüksek doğruluk ve hız sunarken, YOLOv8, daha modern ve hafif bir yapıya sahip olup küçük nesnelerin ve yoğun sahnelerin analizinde üstün performans sağlar. Şekil 14'te örneği görüldüğü gibi özellikle kuş tespiti gibi hassas ve gerçek zamanlı uygulamalarda YOLO'nun bu özellikleri büyük bir avantaj sağlamaktadır. Kuşların küçük boyutları ve karmaşık hareketleri, YOLO'nun hızlı ve doğru tespit yeteneklerini kritik bir gereklilik haline getirir. YOLO'nun bu üstün özellikleri, havacılık gibi hassas sektörlerde uçuş güvenliğini artıran vazgeçilmez bir algoritma olmasını sağlamaktadır.

3.2.1 YOLOv5

YOLOv5, YOLO algoritmasının bir versiyonudur ve Ultralytics tarafından geliştirilmiştir. YOLOv5, önceki YOLO versiyonlarına göre bazı önemli iyileştirmeler ve değişiklikler sunar.

3.2.2. YOLOv5'in Özellikleri

Kolay Kullanım: PyTorch tabanlıdır, bu da geliştirme ve eğitim süreçlerini kolaylaştırır.

Verimlilik: Daha hızlı eğitim ve çıkarım süreleri sunar.

Model Boyutları: YOLOv5, farklı boyutlarda modeller (nano, small, medium, large, ve xlarge) sunar, bu da farklı uygulamalar için esneklik sağlar.

Veri Genişletme (Data Augmentation): Eğitim sırasında veri genişletme teknikleri kullanarak modeli daha genelleştirilebilir hale getirir.

Otomatik Karmaşıklık (Auto Learning Rate & Auto Anchor): Optimal öğrenme oranı ve çapa kutuları gibi parametreleri otomatik olarak ayarlayabilir.

3.3. YOLOv8: Gelişmiş Nesne Tespit Teknolojisi

YOLOv8, nesne algılama, görüntü sınıflandırma ve örnek segmentasyon görevleri için tasarlanmış en yeni ve en gelişmiş YOLO modelidir. Ultralytics tarafından geliştirilen bu model, endüstriyi tanımlayan YOLOv5'in üzerine inşa edilmiş ve bir dizi mimari ve işlevsel iyileştirme içermektedir. YOLOv8, hem doğruluk hem de hız açısından üstün performans sunarak nesne tespiti alanında state-of-the-art bir çözüm haline gelmiştir.

3.3.1 YOLOv8'in Mimarisi

YOLOv8'in mimarisi üç ana bileşenden oluşur: Backbone, Head ve Loss. Bu bileşenler, nesne tespiti sürecinin farklı aşamalarında görev alarak modelin hızlı, doğru ve etkili bir şekilde çalışmasını sağlar.

- **Backbone:** Backbone, giriş görüntüsünden özelliklerin çıkarıldığı temel yapıdır. YOLOv8'in Backbone kısmı, farklı çözünürlüklerdeki nesneleri algılamak için çok katmanlı bir evrişim ağına sahiptir. Bu yapı, hem küçük hem de büyük nesnelerin tespit edilmesini mümkün kılar. Backbone içinde öne çıkan bileşenler şunlardır:

- a) Pyramid Features (P1, P2, P3, P4, P5): Görüntü, farklı ölçeklerde analiz edilerek özellik haritaları çıkarılır. Bu yöntem, küçük nesnelerden büyük nesnelere kadar geniş bir yelpazede tespit yapılmasını sağlar.
- b) C2f Modülü: YOLOv8'de kullanılan C2f modülü, önceki sürümlerde kullanılan C3 modülünün yerini almıştır. Tüm bottleneck çıktılarının birleştirilmesiyle daha fazla bilgi sağlayarak performansı artırır.
- c) SPPF (Spatial Pyramid Pooling - Fast): Farklı çözünürlüklerdeki özellik haritalarını birleştirerek küçük nesnelerin tespit edilmesini kolaylaştırır.
- Head: Head kısmı, Backbone'dan gelen özellikleri analiz ederek nesne tespit sonuçlarını üretir. Özellik haritalarını birleştirerek hem küçük hem de büyük nesnelerin tespit edilmesine olanak tanır. Öne çıkan özellikleri:
 - a) Concat (Concatenation): Farklı çözünürlüklerdeki özellik haritalarını birleştirir.
 - b) Upsample: Küçük nesnelerin tespit edilmesi için düşük çözünürlükteki haritaları yükseltir.
 - c) Detection Layers (P3, P4, P5): Küçük, orta ve büyük ölçekli nesnelerin tespiti için katmanlar içerir.
- Loss (Kayıp Fonksiyonu): YOLOv8'in kayıp fonksiyonu, modelin eğitimi sırasında hata oranlarını ölçmek ve iyileştirmek için kullanılır. Üç ana bileşenden oluşur:
 - a) Bbox (Bounding Box): Tahmin edilen sınır kutularının doğruluğunu ölçer.
 - b) Cls (Classification): Nesnelerin doğru sınıflara atanmasını değerlendirir.
 - c) IoU (Intersection Over Union): Tahmin edilen sınır kutuları ile gerçek kutular arasındaki örtüşmeyi ölçer.

3.3.2. YOLOv8'in Öne Çıkan Özellikleri

YOLOv8, nesne tespiti alanında bir dizi yenilik ve iyileştirme sunar:

- Anchor-Free Detection: YOLOv8, anchor-free bir modeldir. Bu yaklaşım, nesnelerin merkezlerini doğrudan tahmin ederek anchor box uyumsuzluk problemlerini ortadan kaldırır. Anchor-free yapı sayesinde tahmin edilen kutu sayısı azalır, Non-Maximum Suppression (NMS) süreci hızlanır ve genel performans artar.
- C2f Modülü: Önceki C3 modülüne kıyasla daha fazla bilgi sağlayan C2f modülü, tüm bottleneck çıktılarının birleştirilmesiyle daha kapsamlı bir bağlam analizi yapar.

- Parametre Azaltma: Neck kısmında, özellik haritaları doğrudan birleştirilir ve aynı kanal boyutlarına zorlanmaz. Bu yöntem, parametre sayısını azaltarak hesaplama verimliliğini artırır.
- Mosaic Augmentation: YOLOv8, eğitim sırasında çevrimiçi olarak görüntüleri genişletmek için Mosaic Augmentation gibi teknikler kullanır. Bu teknik, modelin nesneleri farklı konumlarda ve çevresel koşullarda öğrenmesini sağlar. Ancak, eğitim sürecinin son 10 döngüsünde bu yöntem kapatılarak doğruluk artırılmıştır.
- COCO Benchmark Performansı: YOLOv8, nesne tespitinde kullanılan COCO veri setinde yüksek doğruluk oranlarına ulaşmış ve aynı hızda çalışan diğer modellerden daha üstün sonuçlar elde etmiştir.

3.3.3. YOLOv8'in Alt Modelleri ve Nano Modelinin Seçimi

YOLOv8, farklı kullanım senaryolarına ve donanım kısıtlamalarına uygun olarak Nano (n), Small (s), Medium (m), Large (l) ve X-Large (x) gibi alt modeller sunmaktadır. Bu alt modeller, hız ve doğruluk arasında bir denge sağlamak amacıyla farklı parametre sayıları ve mimari derinliklerle tasarlanmıştır.

- Nano (n): YOLOv8'in en hafif modeli olup, düşük işlem gücüne sahip cihazlar veya gerçek zamanlı uygulamalar için optimize edilmiştir. Hızlı çalışmasıyla öne çıkan Nano modeli, hafif yapısına rağmen birçok uygulama için yeterli performans sunar.
- Small (s): Small modeli, mobil cihazlar ve gömülü sistemlerde kullanılmak üzere tasarlanmıştır. Nano modeline göre daha yüksek doğruluk oranı sağlar.
- Medium (m): Orta seviye bir yapı sunarak hız ve doğruluk arasında bir denge kurar. Daha karmaşık tespit görevleri ve geniş veri setleri için uygundur.
- Large (l): Daha güçlü donanımlarla çalışmak üzere tasarlanmış olan Large modeli, yüksek doğruluk gerektiren uygulamalarda tercih edilir.
- X-Large (x): En büyük ve en güçlü model olan X-Large, en yüksek doğruluk oranını sunar ancak büyük donanım kaynaklarına ihtiyaç duyar.

Bu tez kapsamında, kuş tespiti görevleri için YOLOv8 Nano modeli tercih edilmiştir. Nano modelinin seçimi, projenin veri seti büyüklüğüne ve donanım gereksinimlerine uygunluğu nedeniyle yapılmıştır. Geliştirilen veri seti, Nano modelinin doğruluk ve performans açısından yeterli olduğu bir yapıdadır. Nano modeli, hızlı çalışması ve düşük kaynak tüketimi sayesinde, tez için hem ekonomik hem de pratik bir çözüm sunmuştur.

Nano modelinin kullanımı, özellikle kuş tespiti gibi gerçek zamanlı ve hassas tespit gerektiren bir uygulamada, verimli bir çalışma ortamı sağlamıştır. Veri setimizin boyutu ve içeriği dikkate alındığında, daha ağır modellere ihtiyaç duyulmadan istenilen doğruluk oranlarına ulaşılmıştır. Bu seçim, hem geliştirme sürecinde zaman kazandırmış hem de donanım maliyetlerini minimize etmiştir. Sonuç olarak, YOLOv8 Nano modeli, tez gereksinimlerini tam anlamıyla karşılayarak etkin bir çözüm sunmuştur.

3.3.4. YOLOv8'in Havacılık Sektöründeki Kullanımı

YOLOv8'in üstün özellikleri, havacılık sektörü gibi hassas alanlarda kullanımını ideal kılar. Özellikle kuş çarpmalarını önlemeye yönelik sistemlerde, küçük nesnelerin algılanmasındaki başarısı ve gerçek zamanlı tespit yeteneği büyük bir avantaj sağlar. YOLOv8'in anchor-free yapısı, kuş tespiti sırasında gereksiz tahminleri ortadan kaldırarak daha doğru sonuçlar elde edilmesini sağlar.

3.3.5 CUDA kullanımı

CUDA, Nvidia tarafından ortaya konulan, bilgisayarın işlem performansına yüksek oranda katkı yapan bir paralel programlama platformudur. C, C++, C#, Fortran, Java, Python gibi programlama dilleri ile yazılmış algoritmaların GPU yani "grafik işlem birimi" üzerinde çalışmasını sağlayan bir sistem olarak da tanımlanabilir. Paralel programlama, birden fazla CPU'nun bir arada çalışmasını istediği için zorluk çıkartır. CPU'lar aslen seri işlemcilerdir ve birden fazla CPU'nun bir arada kullanılabilmesi için karmaşık yazılımlar gerekmektedir. CUDA ise bünyesinde zaten paralellik yarattığı için bu zorlukları ortadan kaldırıyor. CUDA etkinleştirilmiş GPU ile görüntü ve video işlem, hesaplama dayalı biyoloji ve kimya, akışkan dinamiği, bilgisayarlı tomografi, sismik analiz, ışın izleme ve çok daha fazlası dahil olmak üzere geniş bir aralıkta kullanım alanları bulmaktadır. CUDA, sadece NVIDIA GPU'larda çalışması itibariyle rakiplerinden farklı olsa da 2012 yılı itibariyle dünya üzerinde 300 milyondan fazla CUDA destekli GPU olduğu bilinmektedir. Bugün bu sayı daha da üst seviyeye ulaşmıştır. Bu sebeplerden dolayı tez için bu platformdan destek alınmıştır.

3.4. PyTorch Kütüphanesi

PyTorch, Facebook tarafından geliştirilmiş, açık kaynaklı ve derin öğrenme modelleri oluşturmak için yaygın olarak kullanılan bir makine öğrenimi kütüphanesidir. Özellikle araştırma ve prototipleme süreçlerinde esneklik ve kullanıcı dostu API'si ile dikkat çeken PyTorch, makine öğrenimi ve derin öğrenme modelleri geliştirmede kritik bir araç olarak kullanılmaktadır. Bu kütüphane, tensör işlemlerinden sinir ağı modellerine kadar geniş bir

özellik yelpazesi sunar ve GPU hızlandırmalı hesaplama desteği ile büyük veri setleri üzerinde hızlı eğitim yapılmasına olanak tanır.

PyTorch'un temel veri yapısı olan tenzorler (tensors), çok boyutlu dizi yapılarıdır. NumPy dizilerine benzer şekilde tasarlanmış olsalar da, GPU desteği sayesinde büyük ölçekli modellerde yüksek performanslı hesaplama yapılmasını sağlarlar. Bu özellik, özellikle YOLOv8 gibi karmaşık derin öğrenme algoritmalarının uygulanmasında büyük bir avantaj sağlamaktadır. Ayrıca, tenzorlerin otomatik türevlenmesi (automatic differentiation) sayesinde optimizasyon işlemleri ve hata geri yayılımı (backpropagation) süreçleri otomatik olarak gerçekleştirilmektedir. Bu, derin öğrenme modellerinin eğitim süreçlerini kolaylaştırır ve hızlandırır.

3.4.1. PyTorch'un Temel Modülleri

PyTorch, derin öğrenme projelerinde yaygın olarak kullanılan birçok modül sunar. Bu modüller, karmaşık derin öğrenme modellerinin kolayca oluşturulmasına ve optimize edilmesine olanak tanır:

- **torch.nn Modülü:** Sinir ağı katmanlarını, aktivasyon fonksiyonlarını ve kayıp fonksiyonlarını içeren bir modüldür. Örnek olarak, nn.Linear, nn.Conv2d, nn.ReLU ve nn.CrossEntropyLoss gibi bileşenler, derin öğrenme projelerinde sıkça kullanılır.
- **Autograd Modülü:** Türevlerin otomatik olarak hesaplanmasını sağlayan bu modül, gradyan iniş (gradient descent) gibi optimizasyon tekniklerinin uygulanmasını kolaylaştırır. PyTorch'un bu güçlü özelliği, kullanıcıların manuel türev hesaplama ihtiyacını ortadan kaldırır.
- **GPU Hızlandırma:** NVIDIA CUDA desteği ile, PyTorch GPU'ları kullanarak büyük veri setleri üzerinde hızlı hesaplama yapılabilir. Bu, hem eğitim süresini kısaltır hem de model performansını artırır.

3.4.2. PyTorch'un Avantajları

PyTorch, YOLOv8 gibi gelişmiş nesne tespiti algoritmalarının uygulanmasında büyük avantajlar sunmaktadır:

- **Esneklik:** PyTorch'un dinamik hesaplama grafikleri ve modüler yapısı, araştırma ve geliştirme süreçlerini kolaylaştırır.
- **Performans:** GPU hızlandırması sayesinde, büyük ölçekli veri setlerinde hızlı ve verimli eğitim imkanı sağlar.

- **Kullanıcı Dostu API:** Kolay anlaşılabilir ve öğrenilebilir bir yapıya sahiptir. Bu özellik, projelere hızlı başlangıç yapılmasını ve hataların kolayca giderilmesini mümkün kılar.
- **Geniş Ekosistem:** TorchVision ve TorchText gibi modülleri sayesinde, görüntü, metin ve diğer veri türlerinde derin öğrenme projeleri geliştirmek kolaylaşır.
- **Güçlü Topluluk Desteği:** PyTorch, geniş bir kullanıcı topluluğuna sahiptir ve bu da sürekli iyileştirme ve destek almayı kolaylaştırır.

3.4.3. PyTorch'un YOLOv8 ile Entegrasyonu

PyTorch, YOLOv8'in geliştirilmesinde ve uygulanmasında temel bir araç olarak kullanılmaktadır. YOLOv8'in karmaşık yapısı ve yüksek performans gereksinimleri, PyTorch'un GPU destekli hızlı hesaplama ve otomatik türev hesaplama özellikleriyle kolayca karşılanmaktadır. Ayrıca, PyTorch'un modüler yapısı, YOLOv8'in mimarisinin esnek bir şekilde optimize edilmesine ve uyarlanmasına olanak tanımaktadır.

Sonuç

PyTorch, derin öğrenme modellerinin geliştirilmesi ve uygulanması için vazgeçilmez bir kütüphane olarak öne çıkmaktadır. Tensör işlemlerinden sinir ağı mimarilerine kadar geniş bir özellik yelpazesi sunması, YOLOv8 gibi gelişmiş nesne tespiti algoritmalarının başarıyla uygulanmasını sağlamaktadır. PyTorch'un esnekliği, performansı ve kullanıcı dostu yapısı, hem araştırma hem de endüstriyel projelerde etkili bir çözüm sunmaktadır. Bu özellikler, özellikle gerçek zamanlı kuş tespiti gibi kritik uygulamalarda PyTorch'un tercih edilmesini sağlamaktadır.

3.5. Roboflow

YOLOv8'in başarılı bir şekilde nesne tespiti yapabilmesi için kaliteli bir veri setine ihtiyaç duyulmaktadır. Bu bağlamda, bu projede kullanılacak veri setleri, Roboflow platformu kullanılarak hazırlanmıştır. Roboflow, bilgisayarla görme projeleri için veri setlerinin oluşturulması, işlenmesi ve yönetilmesi süreçlerini kolaylaştıran yenilikçi bir platformdur. Özellikle derin öğrenme tabanlı nesne tespiti, görüntü sınıflandırma ve segmentasyon gibi projeler için özel olarak tasarlanmıştır.

Roboflow, veri hazırlama sürecini otomatikleştirerek kullanıcıların zaman ve kaynak tasarrufu sağlamasına olanak tanır. Platform; etiketleme, veri artırma (augmentation) ve format dönüştürme gibi işlemleri kolaylaştırarak, modellerin eğitiminde kullanılacak veri setlerini hızlı ve verimli bir şekilde oluşturur. Bounding box, segmentasyon ve sınıflandırma gibi farklı

etiketleme yöntemlerini destekleyen Roboflow, geniş bir kullanım yelpazesi sunar. Veri artırma teknikleri arasında döndürme, ölçekleme, parlaklık ayarı ve mozaik artırma gibi yöntemler yer almakta olup, bu teknikler modelin genelleme yeteneğini artırmakta ve farklı koşullarda daha dayanıklı hale gelmesini sağlamaktadır.

Roboflow'un bir diğer önemli avantajı, YOLO, COCO ve Pascal VOC gibi popüler formatlara uyumlu olmasıdır. Bu özellik, Roboflow tarafından hazırlanan veri setlerinin TensorFlow, PyTorch ve YOLOv8 gibi framework'lerle kolayca kullanılmasını mümkün kılar. YOLOv8 gibi nesne tespiti algoritmaları için Roboflow, doğru ve hızlı bir şekilde veri etiketleme yapmayı, küçük nesnelerin tespitinde performansı artıran mozaik artırma gibi gelişmiş tekniklerle veri setlerini zenginleştirmeyi ve veri setlerini doğrudan kullanılabilir hale getirmek için gerekli format dönüşümlerini sağlamayı mümkün kılar. Bulut tabanlı yapısı sayesinde, ekiplerin iş birliği yapmasını kolaylaştırır ve veri setlerinin farklı versiyonlarını takip etmeyi sağlar.

Bu projede Roboflow'un tercih edilmesinin en önemli nedenlerinden biri, kuş tespiti gibi karmaşık bir görev için hassas ve yüksek kaliteli veri setleri oluşturabilme kabiliyetidir. Bounding box etiketleme araçları, kuşların sınır kutularını hassas bir şekilde belirlemek için kullanılmıştır. Ayrıca, mozaik artırma gibi gelişmiş veri genişletme teknikleri, veri setini çeşitlendirerek YOLOv8'in küçük nesneleri ve karmaşık sahneleri daha doğru bir şekilde algılamasını sağlamıştır. Roboflow, veri setlerini YOLOv8'in gerektirdiği formata otomatik olarak dönüştürerek hem veri işleme sürecini hızlandırmış hem de olası format uyumsuzluklarını önlemiştir. Farklı veri seti sürümlerini yönetme yeteneği ise, proje boyunca hiperparametrelerin ve veri genişletme tekniklerinin optimize edilmesi için büyük kolaylık sağlamıştır.

Roboflow'un bulut tabanlı altyapısı, ekiplerin aynı veri seti üzerinde eş zamanlı olarak çalışmasına olanak tanırken, yüksek ölçeklenebilirliği sayesinde büyük veri setlerinin yönetimini kolaylaştırmıştır. Bu özellikler, veri seti hazırlama sürecinde ekiplerin verimliliğini artırmış ve YOLOv8'in performansını en üst düzeye çıkarmıştır.

4. VERİ SETİ OLUŞTURMA


Nesne tespiti (object detection) modellerinin başarısı, büyük ölçüde kullanılan veri setlerinin kalitesine ve çeşitliliğine bağlıdır. Bir modelin gerçek dünyadaki nesneleri doğru bir şekilde tanıyıp konumlandırabilmesi, geniş bir görsel yelpazeye sahip, farklı koşulları temsil eden verilerle eğitilmesine dayanır. Farklı açılar, ışık koşulları, nesne boyutları ve çevresel faktörleri içeren bir veri seti, modelin genelleme yeteneğini artırır. Aynı zamanda, dengeli ve tarafsız bir veri kümesi oluşturmak, modelin belirli senaryolara yanlılık göstermesini engeller. Bu nedenle, veri toplama aşamasında kapsamlı ve çeşitli bir içerik sağlanması kritik öneme sahiptir.

Toplanan görsellerin doğru şekilde etiketlenmesi de en az veri toplama kadar önemlidir. Nesnelerin sınıflarının tanımlanması ve konumlarının doğru bir şekilde işaretlenmesi, modelin doğruluk oranını doğrudan etkiler. Hatalı etiketlenmiş veriler, modelin yanlış sonuçlar üretmesine yol açabilir. Bu sürecin titizlikle yürütülmesi, modelin yanlış pozitif ve yanlış negatif oranlarını azaltır ve genel performansı yükseltir. Sonuç olarak, görsel toplama ve veri seti oluşturma süreçlerine yapılan yatırım, nesne tespiti modellerinin doğruluğu, güvenilirliği ve kullanım alanlarındaki başarısı için vazgeçilmezdir.

Veri seti oluşturma işleminin ilk aşamasında algılanmasını istediğimiz kuşlar üzerine bir araştırma yapıp İstanbul çevresinde birçok kez havalimanlarında uçakları tehlikeye atan iri kuşlar ve Türkiye’de çoğunlukta bulunan türler üzerine bir ilerleme sağlandı. Seçilen kuş türleri: Martı(Seagull), Leylek(Stork), Kartal(Eagle), Doğan(Falcon), Güvercin(Pigeon), Baykuş(Owl) ve Karga(Crow) oldu.

4.1.Roboflow Üzerinde Veri Seti Oluşturma

Makine öğrenimi projelerinde başarı, kaliteli bir veri setine dayanır. Özellikle nesne algılama (object detection) problemlerinde veri setinin doğru organize edilmesi, modelin performansını doğrudan etkiler. Bu çalışmada, 7 farklı kuş türünü (Martı, Leylek, Kartal, Doğan, Güvercin, Karga ve Baykuş) içeren, her tür için yaklaşık 200 adet görselden oluşan bir veri seti hazırlanmıştır. Şekil 15’teki Roboflow arayüzü kullanılarak oluşturulan bu veri setinin aşamaları detaylı bir şekilde sonraki başlıklarda açıklanmıştır.



Şekil 15 Roboflow arayüzü

4.1.1. Proje Oluşturma

Project Name Name cannot be empty. License Ⓢ

E.g., 'Dog Breeds' or 'Car Models' or 'Text Finder' . CC BY 4.0

Annotation Group Ⓢ

E.g., 'dogs' or 'cars' or 'words' .

Project Type

Object Detection
Identify objects and their positions with bounding boxes.
Best For # Counting Tracking

Classification
Assign labels to the entire image.
☒ Single-Label ☐ Multi-Label
Best For Filtering Content Moderation

Instance Segmentation
Detect multiple objects and their actual shape.
Best For Measurements Odd Shapes

Keypoint Detection
Identify keypoints ("skeletons") on subjects.
Best For Pose Estimation


Multimodal
Describe images using text pairs.
Best For Visual Question Answering Context Understanding Caption Generation

Şekil 16 Roboflow kullanımı

Şekil 16'daki Roboflow ekran alıntısında görüldüğü gibi kullanıcı dostu arayüzü ile makine öğrenimi projelerinin başlangıç aşamasında kolaylık sağlamaktadır. İlk adım olarak, Roboflow platformuna giriş yapılarak bir proje oluşturulması gerekmektedir. Bu işlem için ana sayfada bulunan **“Create New Project”** butonu kullanılmıştır. Açılan formda proje adına **“Bird_Detection”** adı verilmiş ve proje türü olarak **“Object Detection”** seçilmiştir. Bu seçim, projenin nesne algılama odaklı olmasını ve ilerleyen aşamalarda veri setinin doğru bir şekilde yapılandırılmasını sağlamıştır.

Ardından, YOLOv8 modeli kullanılacağı için format seçimi de yapılmıştır. **YOLOv8** formatı seçilerek, yüklenen görsellerin bu modele uygun şekilde etiketlenmesi ve işlenmesi hedeflenmiştir. Format seçimi, veri setinin eğitim, validasyon ve test aşamalarında kullanılabilirliği açısından kritik bir adımdır.

4.1.2. Veri Seti Yükleme




Şekil 17 Roboflow üzerinden veri seti oluşturma

Veri seti yükleme aşaması, görsellerin organize bir şekilde projeye aktarılmasını içerir. Bu çalışmada her kuş türüne ait görseller, tür bazında sınıflandırılarak hazırlanmıştır. Örneğin, Martı, Leylek ve diğer türlere ait görseller ayrı klasörlerde tutulmuş ve her tür için yaklaşık 200 görsel kullanılmıştır. Şekil 17'de görüldüğü gibi görsellerin toplu halde yüklenmesi için Roboflow'un "Upload" aracı kullanılmıştır.

Roboflow, yükleme işlemi sırasında görselleri otomatik olarak analiz ederek çözünürlük ve boyut gibi parametreleri optimize etmiştir. Platform, gerekli durumlarda görsellerin çözünürlüğünü ölçeklendirmiş ve veri setini modele uygun bir forma dönüştürmüştür. Bu süreçte, veri setinin homojenliği ve çeşitliliği sağlanarak modelin genelleme kapasitesini artırmak hedeflenmiştir.


4.1.3. Görsellerin Etiketlenmesi



Şekil 18 Görsel etiketleme işlemi


Veri seti oluşturma sürecinin en önemli aşamalarından biri etiketleme işlemidir. Etiketleme, her görselde yer alan kuş türlerinin belirli bir dikdörtgen kutu (bounding box) ile işaretlenmesiyle gerçekleştirilmiştir. Bu işlem sırasında, görsellerdeki her bir kuşun türü doğru bir şekilde tanımlanmış ve tür etiketi eklenmiştir. Şekil 18’de ve Şekil 19’da bir örnek ekran alıntısı gösterilmiştir.

Roboflow, hem manuel hem de otomatik etiketleme seçenekleri sunmaktadır. Manuel etiketleme yöntemiyle her kuş türü dikkatlice işaretlenmiş ve etiketlenmiştir. Bu süreçte veri集中的 tutarlılık korunmuş ve yüksek kaliteli bir etiketleme süreci gerçekleştirilmiştir.



Şekil 19 Etiketlenen görsel

4.1.4. Veri Setinin İyileştirilmesi



Şekil 20 Örnek veri seti

Makine öğrenimi modellerinin eğitimi sırasında veri setinin doğru ve tutarlı bir şekilde etiketlenmesi, modelin performansını doğrudan etkileyen önemli bir adımdır. Bu projede kullanılan görseller, Roboflow platformu aracılığıyla etiketlenmiştir. Şekil 20'deki gibi her görselde bulunan kuş türleri, belirli bir dikdörtgen kutu (bounding box) ile işaretlenmiş ve ilgili tür etiketi atanmıştır. Etiketleme sırasında dikkat edilen temel unsurlar arasında doğru sınıf ataması, nesne sınırlarının net bir şekilde belirlenmesi ve görsellerdeki tüm hedef nesnelerin işaretlenmesi yer almaktadır.

Create New Version

Prepare your images and data for training by compiling them into a version. Experiment with different configurations to achieve better training results.

✓

Source Images

Images: 1,206
Classes: 7
Unannotated: 0

✓

Train/Test Split

Training Set: 844 images
Validation Set: 242 images
Testing Set: 120 images

3

Preprocessing

What can preprocessing do?
Decrease training time and increase performance by applying image transformations to all images in this dataset.

Auto-Orient

Edit

×

Resize

Stretch to 640×640

Edit

×

Grayscale

Edit

×

+

Add Preprocessing Step

Continue

4

Augmentation


5

Create

Şekil 21 Veri seti iyileştirmesi (augmentation)

Etiketleme işlemi tamamlandıktan sonra, veri setinin iyileştirilmesi aşamasına geçilmiştir. Veri setini iyileştirme sürecinin temel amacı, modelin genelleme yeteneğini artırmak ve farklı koşullarda daha iyi performans göstermesini sağlamaktır. Bu amaç doğrultusunda, veri setine çeşitli artırma (augmentation) teknikleri uygulanmıştır. Augmentation işlemleri, veri setini zenginleştirerek modelin öğrenme kapasitesini artırmakta ve veri çeşitliliği sayesinde aşırı öğrenme (overfitting) riskini azaltmaktadır. Şekil 21 ve Şekil 22’de augmentation sekmesinin bölümleri görülmektedir.

4.1.4.1. Augmentation Teknikleri ve Uygulama Nedenleri:



Şekil 22 Augmentation çeşitleri

Bu çalışmada kullanılan artırma teknikleri arasında döndürme (rotation), parlaklık ayarı (brightness adjustment), bulanıklık (blur) ve gürültü ekleme (noise addition) bulunmaktadır. Bu tekniklerin uygulanma nedenleri ve etkileri aşağıda detaylı olarak açıklanmıştır:

- **Döndürme (Rotation)**; Görseller, saat yönünde ve saat yönünün tersine 90 derece döndürülmüş, ayrıca -15 derece ile +15 derece arasında rastgele döndürme işlemleri yapılmıştır. Bu işlemin amacı, modelin farklı açılardan gelen nesneleri algılayabilme kapasitesini artırmaktır. Gerçek hayatta kuşların farklı açılardan görüntülenebileceği göz önünde bulundurulduğunda, bu teknik modelin genelleme yeteneği üzerinde olumlu bir etki sağlamaktadır.
- **Parlaklık Ayarı (Brightness Adjustment)**; Görsellerin parlaklık değerleri %25 oranında artırılmış veya azaltılmıştır. Bu, farklı ışık koşullarında modelin performansını iyileştirmek için yapılmıştır. Örneğin, bir kuş türü hem güneşli bir ortamda hem de gölgede görüntülenebileceğinden, bu teknik ışık değişimlerine karşı modelin duyarlılığını artırmaktadır.


- Bulanıklık (Blur); Görsellere 1.25 kata kadar bulanıklık uygulanmıştır. Bu işlem, bulanık ya da düşük kaliteli görüntülerin model üzerindeki etkisini değerlendirmek ve modelin bu tür durumlarda dahi doğru sonuçlar verebilmesini sağlamak için önemlidir.
- Gürültü Ekleme (Noise Addition); Görsellerin %5'ine kadar rastgele gürültü eklenmiştir. Bu işlem, gerçek hayatta sensör hataları veya çevresel faktörlerden kaynaklanan bozulmaları simüle ederek modelin daha dayanıklı hale gelmesini sağlamıştır.

Bu artırma teknikleri sayesinde, YOLOv8 modelinin veri seti üzerindeki genelleme yeteneği artırılmış ve farklı çevresel koşullarda daha doğru tahminler yapması sağlanmıştır. Görsellerdeki çeşitlilik, modelin yalnızca belirli bir veri kümesine uyum sağlamasını değil, aynı zamanda yeni ve benzer durumlara da uygun yanıtlar verebilmesini sağlamıştır. Augmentation işlemleri, veri setinin sınırlı sayıda görsel içermesine rağmen, bu görsellerden elde edilen bilgi miktarını önemli ölçüde artırmıştır.

Sonuç olarak, bu işlemler, modelin sahada uygulanabilirliğini artıran, gerçek dünya koşullarını simüle eden ve veri setinin etkinliğini yükselten bir katkı sağlamıştır. Bu süreç, makine öğrenimi projelerinde veri setinin kalitesini artırma ve sonuçların doğruluğunu iyileştirme açısından kritik bir öneme sahiptir.

Son olarak, iyileştirilen veri seti YOLOv8 formatında dışa aktarılmıştır. Roboflow, veri setinin eğitim, validasyon ve test aşamalarına uygun bir şekilde bölünmesine de olanak tanımaktadır. Bu projede, veri setinin %70'i eğitim, %20'si validasyon ve %10'u test için ayrılmıştır. Böylece modelin performansını değerlendirmek için dengeli bir yapı elde edilmiştir.

4.2. Roboflow Üzerinden Veri Setinin Dışarı Aktarılması



Şekil 23 Veri setinin dışarı aktarımı

Roboflow, makine öğrenimi modelleri için veri seti hazırlama sürecini kolaylaştırmakla kalmaz, aynı zamanda bu veri setini hedef modelin gereksinimlerine uygun formatta dışarı aktarmayı da sağlar. Şekil 23'te yöntemi gösterilmektedir. YOLOv8 modeli için dışarı aktarım süreci, dikkatlice takip edilmesi gereken birkaç adımdan oluşur. Bu süreç, veri setinin modellenmesi ve eğitimi için uygun hale getirilmesini amaçlar.

4.2.1. Dışa Aktarım Formatının Belirlenmesi

Roboflow'da veri setini dışarı aktarmadan önce, kullanılacak makine öğrenimi modeline uygun formatın seçilmesi gerekir. YOLOv8 modeli için, platformda dışarı aktarım sırasında "YOLOv8 PyTorch Export" seçeneği işaretlenir. Bu format, YOLOv8'in veri yükleme ve eğitim modülleri ile tam uyumlu bir yapıya sahiptir. Dışarı aktarılan veri seti, YOLOv8'in ihtiyaç duyduğu etiket yapısını ve dizin hiyerarşisini içerir.

4.2.2. Veri Setinin Eğitim, Doğrulama ve Test İçin Bölünmesi

Veri setinin dışarı aktarımında, görsellerin eğitim (training), doğrulama (validation) ve test (testing) olarak üç ana bölüme ayrılması önemlidir. Roboflow, bu bölünmeyi kullanıcı tarafından belirlenen oranlara göre otomatik olarak gerçekleştirir. Örneğin:

- Eğitim Seti: Veri setinin %70'i, modelin öğrenmesi için kullanılır.

- Doğrulama Seti: Veri setinin %20'si, modelin eğitim sırasında doğruluğunu değerlendirmek için ayrılır.
- Test Seti: Veri setinin %10'u, eğitilen modelin performansını değerlendirmek için kullanılır.

Bu bölünme, modelin genelleme kapasitesini doğru bir şekilde ölçmek ve veri setindeki dengesizlikleri önlemek için kritik bir adımdır.

4.2.3. Veri Setinin İndirilmesi

Dışa aktarım işlemi sırasında, Roboflow kullanıcılara veri setini bir zip dosyası olarak indirme imkânı sunar. Kullanıcı, “Generate” butonuna tıklayarak veri setinin istenen formatta hazırlanmasını sağlar. Veri seti başarıyla oluşturulduktan sonra, “Download” seçeneği ile yerel bilgisayara indirilebilir. YOLOv8 formatında indirilen veri seti, genellikle şu dizin yapısını içerir:

- /train: Eğitim setine ait görseller ve etiketler.
- /valid: Doğrulama setine ait görseller ve etiketler.
- /test: Test setine ait görseller ve etiketler.

Her dizin, görsellerin yer aldığı bir alt klasör ve etiket bilgilerinin yer aldığı bir metin dosyası içerir. Etiketler, YOLO formatına uygun şekilde, her satırda sınıf etiketi ve nesne konum bilgileri (bounding box koordinatları) ile temsil edilir.


5. MODELİN EĞİTİMİ

Makine öğrenimi projelerinde model eğitimi, veri setinin doğru bir şekilde hazırlanmasının ardından başlar. YOLOv8'in en hafif ve hızlı modeli olan YOLOv8n (nano), özellikle düşük işlem gücü gereksinimleri olan projelerde etkili sonuçlar sunar. Bu projede de kullanılan veri setinde bulunan görsel sayısının görece az olmasıyla beraber nano modeli daha optimum bir model olarak öne çıktı ve bu model üzerinden eğitimler gerçekleştirildi. Ayrıca, model eğitiminde Anaconda Prompt kullanıldı.


5.1. Gerekli Ortamın Hazırlanması

Eğitim işlemine başlamadan önce, uygun yazılım ortamının oluşturulması gerekir. Anaconda, bu tür projelerde Python kütüphanelerini yönetmek için ideal bir araçtır. Aşağıdaki adımlar, gerekli ortamın oluşturulmasını ve YOLOv8'in yüklenmesini içerir:

- Anaconda Ortamı Oluşturma;




```
(base) C:\Users\Onur>conda create -n yolov8-env python=3.13 -y|
```



```
(base) C:\Users\Onur>conda activate yolov8-env|
```

Bu komut, Python 3.8 sürümüyle *yolov8-env* adlı yeni bir ortam oluşturur ve etkinleştirir.

- Ultralytics Paketini Yükleme: YOLOv8 modellerini çalıştırmak için gerekli olan ultralytics kütüphanesi yüklenir:



```
(base) C:\Users\Onur>pip install ultralytics
```

Ayrıca, diğer gerekli kütüphaneler (örneğin, PyTorch) ultralytics paketiyle otomatik olarak yüklenir.

- GPU Desteği: Eğitim işlemini hızlandırmak için GPU kullanılacaksa, CUDA ve cuDNN sürücülerinin uyumlu versiyonları sistemde kurulu olmalıdır. GPU destekli bir PyTorch sürümü yüklemek için:

```
Anaconda Prompt
(base) C:\Users\Onur>conda install pytorch torchvision torchaudio pytorch-cuda=11.8 -c pytorch -c nvidia|
```

5.2. Veri Setinin Eğitime Hazırlanması

Roboflow'dan indirilen veri seti bir .zip dosyası şeklindedir. Bu dosya, proje dizinine çıkarılarak kullanıma hazır hale getirilir:

Veri seti dizini şu şekilde düzenlenmelidir:


```
! data.yaml C:\...\bird_detection.v2i.yolov8
! data.yaml C:\...\b04b2bc9-eba3-43f2-bd13-ea04f14f58bd_crows.v1i.yolov8.zip.8bd

C: > Users > Onur > Desktop > tez > dataset > bird_detection.v2i.yolov8 > ! data.yaml
1  train: ../train/images
2  val: ../valid/images
3  test: ../test/images
4
5  nc: 8
6  names: ['Crow', 'Eagle', 'Falcon', 'Owl', 'Pigeon', 'Seagull', 'Stork']
7
8  roboflow:
9    workspace: birdspecies
10   project: bird_detection-3rro7
11   version: 2
12   license: CC BY 4.0
13   url: https://universe.roboflow.com/birdspecies/bird_detection-3rro7/dataset/2
```

Bu yapı, YOLOv8'in veri seti yapısı ile uyumludur.

5.3. Model Eğitime Başlanması

Eğitim metni için bir *config* dosyası veya direkt komut satırı parametreleri kullanılabilir. YOLOv8 eğitimini başlatmak için temel komut şu şekildedir:



```
(base) C:\Users\Onur>activate pytorch
(pytorch) C:\Users\Onur>yolo task=detect/mode=train/model=yolov8s.pt/data={C:\Users\Onur\Desktop\tez\dataset\bird_detection.v1i.yolov8}/data.yaml/epochs=100/imgsz=640
```

Bu komutta yer alan parametreler:

- data: Veri setinin konumunu ve sınıf bilgilerini içeren data.yaml dosyasının yolu. Roboflow, bu dosyayı otomatik olarak oluşturur.
- model: YOLOv8'in önceden eğitilmiş nano modeli (*yolov8n.pt*).
- epochs: Eğitim işlemi sırasında modelin veri seti üzerinde kaç kez çalışacağını belirtir (projede 100 epoch).
- imgsz: Görsellerin boyutunu belirtir (örneğin, 640x640 piksel).

5.3.1. Eğitim Sürecinin İzlenmesi

epoch	train/box	train/cls	train/df	metrics/p	metrics/re	metrics/m	metrics/m	val/box_lc	val/cls_lo	val/df_lo	lr/pg0	lr/pg1	lr/pg2
1	1.4825	3.3951	1.6856	0.24226	0.30522	0.19824	0.11249	1.3662	2.9181	1.5725	0.000276	0.000276	0.000276
2	1.4796	2.8895	1.6856	0.19459	0.33861	0.21013	0.11596	1.5457	2.8273	1.7527	0.000548	0.000548	0.000548
3	1.5358	2.694	1.7083	0.23885	0.39833	0.21465	0.11608	1.6885	2.5911	1.8386	0.000815	0.000815	0.000815
4	1.5131	2.5103	1.6928	0.40095	0.39158	0.35437	0.20539	1.4786	2.1373	1.6627	0.000808	0.000808	0.000808
5	1.5107	2.3304	1.6739	0.34934	0.45872	0.33681	0.18336	1.4425	2.0028	1.6175	0.000808	0.000808	0.000808
6	1.4941	2.2426	1.6685	0.36945	0.50021	0.41078	0.24725	1.3434	1.8729	1.5287	0.0008	0.0008	0.0008
7	1.4357	2.1404	1.6148	0.4355	0.47616	0.45632	0.27706	1.3817	1.9224	1.5992	0.000792	0.000792	0.000792
8	1.4242	2.0466	1.6178	0.55672	0.41065	0.44156	0.25802	1.4154	2.0426	1.6354	0.000784	0.000784	0.000784
9	1.4108	1.9846	1.5943	0.36474	0.52848	0.40789	0.2319	1.3573	1.7854	1.5635	0.000775	0.000775	0.000775
10	1.3797	1.8796	1.5705	0.61244	0.54357	0.57659	0.36979	1.2451	1.4917	1.4644	0.000767	0.000767	0.000767
11	1.3655	1.8602	1.5659	0.53827	0.53691	0.58445	0.38042	1.2861	1.523	1.515	0.000759	0.000759	0.000759
12	1.3536	1.8224	1.5543	0.65767	0.58366	0.65	0.39912	1.2981	1.3662	1.5043	0.000751	0.000751	0.000751
13	1.3561	1.761	1.5513	0.58993	0.60951	0.60195	0.36257	1.3395	1.4488	1.5079	0.000742	0.000742	0.000742
14	1.3576	1.7272	1.5445	0.60438	0.59331	0.62242	0.39222	1.2084	1.4065	1.4383	0.000734	0.000734	0.000734
15	1.3171	1.6618	1.5257	0.5631	0.57752	0.60492	0.36675	1.257	1.4888	1.4679	0.000726	0.000726	0.000726
16	1.3165	1.6371	1.5153	0.62918	0.48715	0.53558	0.31655	1.2862	1.6416	1.4992	0.000718	0.000718	0.000718
17	1.3088	1.628	1.5116	0.7168	0.61578	0.70763	0.46245	1.186	1.2213	1.4228	0.000709	0.000709	0.000709
18	1.3049	1.566	1.4958	0.62505	0.60905	0.66924	0.43781	1.1904	1.2658	1.4413	0.000701	0.000701	0.000701
19	1.2824	1.5664	1.4896	0.58586	0.67616	0.65739	0.41655	1.2195	1.3493	1.4056	0.000693	0.000693	0.000693
20	1.2675	1.5253	1.4922	0.61302	0.57026	0.63173	0.37232	1.303	1.398	1.4977	0.000685	0.000685	0.000685
21	1.2838	1.4902	1.4773	0.64964	0.61095	0.67645	0.43894	1.2175	1.2666	1.4107	0.000676	0.000676	0.000676
22	1.2677	1.4386	1.4683	0.73863	0.60227	0.71813	0.45897	1.2049	1.2021	1.4186	0.000668	0.000668	0.000668
23	1.2526	1.4294	1.4623	0.67544	0.68214	0.72557	0.46542	1.1845	1.1899	1.4057	0.00066	0.00066	0.00066
24	1.258	1.3877	1.4556	0.67836	0.63535	0.70993	0.46514	1.2383	1.1897	1.412	0.000652	0.000652	0.000652
25	1.2309	1.3771	1.4468	0.76938	0.63287	0.74046	0.48092	1.1616	1.1531	1.3779	0.000643	0.000643	0.000643
26	1.2182	1.3529	1.4462	0.65561	0.66696	0.71319	0.46488	1.1885	1.1419	1.395	0.000635	0.000635	0.000635
27	1.2173	1.3574	1.451	0.71872	0.65214	0.7023	0.45253	1.1568	1.2487	1.3775	0.000627	0.000627	0.000627
28	1.2192	1.3291	1.4427	0.74987	0.63324	0.72506	0.46741	1.1863	1.1393	1.3864	0.000619	0.000619	0.000619
29	1.2151	1.3175	1.4352	0.703	0.60888	0.72402	0.47506	1.201	1.1736	1.4035	0.00061	0.00061	0.00061
30	1.1919	1.2646	1.4213	0.68797	0.7383	0.75381	0.48209	1.1928	1.0905	1.4067	0.000602	0.000602	0.000602
31	1.1966	1.2626	1.4268	0.74133	0.72336	0.76471	0.48506	1.1896	1.0519	1.4053	0.000594	0.000594	0.000594
32	1.1951	1.2527	1.4159	0.66216	0.74561	0.75296	0.4984	1.1922	1.0404	1.3788	0.000586	0.000586	0.000586
33	1.1806	1.2517	1.4092	0.73699	0.73713	0.77553	0.5186	1.1481	1.034	1.3628	0.000577	0.000577	0.000577
34	1.1769	1.2039	1.4048	0.6995	0.68986	0.72078	0.46263	1.1467	1.1754	1.3773	0.000569	0.000569	0.000569

Eğitim işlemi başladıktan sonra, terminal üzerinde aşağıdaki bilgiler görüntülenir:

- Epoch: Mevcut epoch sayısı ve toplam epoch.
- Loss: Modelin öğrenme sürecini değerlendiren hata oranı.
- Accuracy (mAP): Modelin doğruluk performansı.
- Time: Her epoch için geçen süre.

Eğitim sırasında GPU kullanılıyorsa süreç daha hızlı tamamlanır. Eğitim sonuçları, model performansını ölçmek için runs/train/exp dizininde kaydedilir.

5.4. Modelin Kullanımı

Eğitim tamamlandığında, model tahmin (inference) işlemi için hazır hale gelir. Eğitilen modeli test etmek için:

```
Anaconda Prompt
(base) C:\Users\Onur>activate pytorch
(pytorch) C:\Users\Onur>yolo mode=predict task=detect source="C:\Users\Onur\Desktop\tez\dataset\testgörsel.jpg" imgsz=640
model=C:\Users\Onur\runs\detect\train2\weights\best.pt
```

Bu komut, test görsel ismindeki görsel üzerinde tahmin işlemi yapar ve sonucu görsel olarak kaydeder.

5.4.1. Modelimiz Üzerinden Alınan Tahmin Sonuçları

Şekil 24, Şekil 25, Şekil 26, Şekil 27 modelin çıktısı olan tahminlerdir.




Şekil 24 Model tahmini 1

Model bu leylek görselini 0.95 kesinlikle yani %95 ihtimalle leylek olarak olarak tanımlamış.



Şekil 25 Model tahmini 2

Model bu martı görselini 0.89 kesinlikle yani %89 ihtimalle martı olarak tanımlamış.



Şekil 26 Model tahmini 3

Model bu Karga görselini 0.80 kesinlikle yani %80 ihtimalle Karga olarak tanımlamış.



Şekil 27 Model tahmini 4

Model bu dođan görselini 0.86 kesinlikle yani %86 ihtimalle dođan olarak olarak tanımlamış.

6. DERİN ÖĞRENME MODEL PERFORMANSI

6.1. Karışıklık Matrisi

Karışıklık Matrisi, sınıflandırma modellerinin performansını değerlendirmek için kullanılan bir tablodur. Bu matris, modelin yaptığı tahminlerle gerçek sonuçları karşılaştırarak hataları ve doğruları analiz etmeye olanak tanır. Özellikle sınıflandırma problemlerinde, doğru ve yanlış tahminleri dört farklı kategoriye ayırır:

- True Positive (TP): Modelin doğru olarak pozitif sınıfta tahmin ettiği örneklerdir. Yani, modelin "pozitif" olarak tahmin ettiği ve gerçekten de pozitif olan sonuçlar.
- True Negative (TN): Modelin doğru olarak negatif sınıfta tahmin ettiği örneklerdir. Yani, modelin "negatif" olarak tahmin ettiği ve gerçekten de negatif olan sonuçlar.
- False Positive (FP): Modelin pozitif tahmin ettiği, fakat aslında negatif olan örneklerdir.
- False Negative (FN): Modelin negatif tahmin ettiği, fakat aslında pozitif olan örneklerdir.


Confusion matrix, genellikle tablo 2’de olduğu gibi gösterilir.

	Gerçek Pozitif	Gerçek Negatif
Tahmin Pozitif	TP(True positive)	FP(False Positive)
Tahmin Negatif	FN(False Negative)	TN(True Negative)

Tablo 2 Confusion matrix çıktısı anlamı

Bu matris sayesinde modelin doğruluğu (accuracy), kesinliği (precision), duyarlılığı (recall) ve F1 skoru gibi performans metrikleri hesaplanabilir. Bu metrikler, modelin sınıflandırma başarısını ve yanlış sınıflandırma durumlarını anlamada önemli bilgiler sağlar.

6.1.1. Modelimizin Karışıklık Matrisi Çıktısının Değerlendirmesi



Şekil 28 Karışıklık Matrisi

Projemizdeki Şekil 28’de gösterilen karışıklık matrisi sonucuna bakacak olursak, belirli kuş türleri ve bir arka plan kategorisine göre sınıflandırma modelinin performansını göstermektedir. Matrisin satırları, modelin yaptığı tahminleri; sütunları ise gerçek sınıfları ifade etmektedir. Diyagonal üzerindeki hücreler, modelin doğru sınıflandırdığı örnekleri temsil ederken, diyagonal dışındaki hücreler modelin hatalı sınıflandırdığı durumları göstermektedir.

Örneğin, Seagull (martı) sınıfı için model, 99 örneği doğru bir şekilde sınıflandırmış ancak 6 örneği Stork (leylek) olarak yanlış sınıflandırmıştır. Bu, Seagull (martı) sınıfında yüksek bir doğru sınıflandırma oranına işaret etmektedir. Falcon (şahin) sınıfında ise 29 doğru sınıflandırma yapılırken 9 örnek Pigeon (güvercin) ve 4 örnek Seagull (martı) olarak yanlış tahmin edilmiştir. Bu durum, Falcon ve Pigeon sınıfları arasında bir karışıklık olduğunu göstermektedir.

Crow (karga) sınıfında 28 doğru tahmin yapılırken yalnızca 1 örnek yanlış sınıflandırılmıştır, bu da bu sınıfta yüksek bir doğruluk oranına işaret eder. Diğer yandan, Pigeon sınıfında 34 doğru tahmin yapılmış ancak model 4 örneği Seagull (martı) ve 1 örneği Falcon olarak yanlış

sınıflandırmıştır. Background (arka plan) sınıfında model yalnızca 7 örneği doğru olarak tanımlayabilmiş ve diğer sınıflarla karışıklık yaşamıştır. Bu durum, arka plan sınıflandırma başarısının ortalama olduğunu göstermektedir.

Genel olarak matris, modelin bazı kuş türlerinde başarılı olduğunu, ancak Falcon-Pigeon gibi benzer türlerde hata oranının daha yüksek olduğunu göstermektedir. Özellikle Seagull sınıfında oldukça yüksek bir doğruluk oranı gözlemlenmekte, ancak arka plan sınıfında ortalama bir başarı sağlanmaktadır.

6.2. Kesinlik Eğrisi (Precision Curve)

Precision (kesinlik), sınıflandırma problemlerinde bir derin öğrenme modelinin, pozitif olarak sınıflandırdığı örneklerin ne kadarının gerçekten pozitif olduğunu ölçen bir metriktir. Precision, özellikle dengesiz veri kümelerinde veya yanlış pozitiflerin bize verdiği zararın yüksek olduğu durumlarda önemli bir değerlendirme aracıdır.

Matematiksel olarak, precision şu formülle hesaplanır:


$$Precision = \frac{True\ Positives\ (TP)}{True\ Positives\ (TP) + False\ Positives\ (FP)}$$

Precision Denklemi

Kesinlik-Güven eğrisi, sınıflandırma modellerinin performansını incelemek amacıyla kullanılan bir grafik türüdür ve modelin farklı eşik değerlerindeki kesinlik (precision) değerlerini göstermektedir. Grafikte, x eksenini modelin öngörülerine dair güven düzeyini (confidence) ifade ederken, y eksenini ilgili güven seviyesinde elde edilen kesinlik değerini göstermektedir. Yüksek bir kesinlik, modelin pozitif sınıf olarak sınıflandırdığı örneklerin çoğunun doğru sınıflandırıldığını ifade eder. Güven seviyesi arttıkça, kesinlik değeri de genellikle yükselir; çünkü daha yüksek güven düzeylerinde yapılan tahminlerin doğruluğu artma eğilimindedir.

P-Curve, model performansını değerlendirirken önemli bilgiler sunar. Örneğin, düşük güven seviyelerinde bile yüksek kesinlik elde ediliyorsa, model daha düşük güven seviyelerinde dahi güvenilir sonuçlar üretebilir. Bu tür bir analiz, modelin doğruluğu ve güven seviyesi arasındaki dengeyi inceleyerek, özellikle kritik sınıflandırma görevlerinde uygun bir eşik değeri seçmeye yardımcı olur.

6.2.1. Modelimizin Doğruluk Çıktısının Değerlendirmesi



Şekil 29 Doğruluk eğrisi

Şekil 29'daki P-Curve grafiğinde, modelinizin farklı kuş türleri (Crow, Eagle, Falcon, Owl, Pigeon, Seagull, Stork) için kesinlik ve güven değerleri arasındaki ilişki görselleştirilmiştir. Grafikte görüldüğü üzere, modelin her bir kuş türü için farklı performans eğrileri sergilediği gözlemlenmektedir.

Crow (karga) türü için yüksek güven seviyelerinde oldukça yüksek bir kesinlik oranı elde edilmiştir; bu, modelin bu sınıfı tanımakta başarılı olduğunu göstermektedir. Stork (leylek) ve Owl (baykuş) sınıfları ise, özellikle düşük güven seviyelerinde daha düşük kesinlik değerleri sergilemiştir, ancak güven seviyesi arttıkça kesinlikte iyileşme görülmektedir. Pigeon (güvercin) sınıfı, güven seviyesinin artmasıyla daha stabil bir kesinlik gösterirken, bazı sınıflarda güven arttıkça büyük sıçramalar görülmektedir. Bu durum, modelin bazı türlerde tahminlerini yaparken daha fazla zorlandığını ve yüksek güven seviyelerine çıkıldıkça daha doğru sonuçlar verdiğini işaret etmektedir.

Grafikte tüm sınıflar için çizilen kalın mavi çizgi, tüm kuş türleri için ortalama kesinlik değerlerini göstermektedir ve 0.973 güven seviyesinde %100 kesinlik oranına ulaşılmıştır. Bu,

modelinizin genel anlamda yüksek güven seviyelerinde oldukça isabetli sonuçlar verdiğini ve pozitif sınıfları doğru bir şekilde tanımlayabildiğini göstermektedir.

6.3. Duyarlılık Eğrisi (Recall Curve)

Recall (duyarlılık ya da geri çağırma), sınıflandırma problemlerinde modelin pozitif sınıfa ait örnekleri ne kadar iyi bulabildiğini gösteren bir metriktir. Recall, özellikle yanlış negatiflerin bize verdiği zararı yüksek olduğu durumlarda önemlidir, çünkü gerçek pozitifleri bulma oranını ölçer.

Matematiksel olarak, recall şu formülle hesaplanır:

$$Recall = \frac{True\ Positives\ (TP)}{True\ Positives\ (TP) + False\ Negatives\ (FN)}$$

Duyarlılık denklemi


Bu formülde:

- True Positives (TP): Modelin doğru bir şekilde pozitif olarak sınıflandırdığı örneklerdir.
- False Negatives (FN): Modelin negatif olarak sınıflandırdığı, fakat aslında pozitif olan örneklerdir.

Yüksek bir recall değeri, modelin pozitif sınıfa ait örneklerin çoğunu yakalayabildiğini gösterir. Örneğin, bir hastalık tarama testinde yüksek recall, hasta olan kişilerin büyük bir kısmının doğru şekilde hasta olarak tanımlanmasını sağlar, böylece kaçırılan (yanlış negatif) vakaların oranı düşük olur. Bu tür durumlarda recall önemlidir, çünkü yanlış negatif sonuçların ciddi sonuçları olabilir.

Duyarlılık Eğrisi (Recall-curve), bir modelin farklı güven (confidence) seviyelerine göre duyarlılığını (recall) gösteren bir eğridir. Bu eğri, sınıflandırma modelinin güven değeri belirli bir eşiğin üzerinde olduğunda pozitif örnekleri doğru bir şekilde tanıma yeteneğini inceler. Modelin duyarlılığı (recall), güven eşiğine bağlı olarak nasıl değiştiğini görselleştiren bu eğri, modelin farklı güven seviyelerinde pozitif sınıfa ait örnekleri ne kadar iyi tespit ettiğini ortaya koyar. Örneğin, bir güven eşiği düşük tutulduğunda, model daha fazla pozitif örneği yakalayabilir ve recall yüksek olur, ancak bu durumda yanlış pozitiflerin de artması muhtemeldir. Yüksek güven eşiğinde ise model, yalnızca daha kesin tahminler yapacağı için recall genellikle azalır.

6.3.1. Modelimizin Duyarlılık Çıktısının Değerlendirmesi



Şekil 30 Duyarlılık Eğrisi

Şekil 30’da gösterilen grafikte, her bir kuş türü için modelin farklı güven eşliğinde duyarlılık performansı gösterilmektedir. Genel olarak, eğri başlarında yüksek bir recall değeriyle başlayan model, güven eşiği arttıkça daha düşük recall değerlerine düşmektedir. Bu, modelin düşük güven eşliğinde pozitif örnekleri daha iyi yakaladığını, ancak güven eşiği arttıkça doğru pozitif tahmin yapma yeteneğinin düştüğünü göstermektedir.

Grafığın sağ tarafına yaklaşıldıkça (yüksek güven seviyelerinde) tüm sınıflar için recall değerlerinin azaldığı görülüyor. Özellikle “Seagull (Martı)” sınıfı için (kahverengi çizgi) belirli bir güven eşiğinin üzerinde recall hızlı bir düşüş göstermekte. Bu, modelin yüksek güven seviyelerinde “Seagull (Martı)” sınıfındaki örnekleri tanıma konusunda daha az duyarlı olduğunu gösteriyor. Genel olarak, tüm sınıfların ortalaması olarak gösterilen koyu mavi çizgi, modelin tüm sınıflarda 0.97’lik bir recall seviyesine ulaştığını belirtmektedir, bu da modelin düşük güven eşiklerinde oldukça iyi bir performans gösterdiğini ortaya koyar.

6.4. Doğruluk-Duyarlılık Eğrisi (PR-Curve)

Precision-Recall (PR) eğrisi, bir sınıflandırma modelinin performansını değerlendirirken yaygın olarak kullanılan bir grafik türüdür. PR eğrisi, modelin doğru pozitif tahmin oranını (Precision) ve pozitif sınıfa ait tüm örnekleri bulabilme yeteneğini (Recall) bir arada gösterir. Precision, bir sınıflandırıcının pozitif olarak tahmin ettiği örneklerin ne kadarının gerçekten pozitif olduğunu ifade ederken, Recall ise modelin pozitif sınıfa ait örnekleri bulmadaki başarısını ölçer. PR eğrisi, bu iki metriğin farklı eşik değerlerinde nasıl değiştiğini görselleştirir.

Genellikle PR eğrisi, özellikle pozitif ve negatif sınıflar arasında dengesizlik olduğunda veya sınıflar arası dengesiz veri kümelerinde model performansını değerlendirmek için daha uygundur. Dengesiz veri kümelerinde, yalnızca doğruluk (accuracy) metriğine bakmak yanıltıcı olabilir, çünkü sınıflar arasında büyük bir oran farkı olduğunda model çoğunluk sınıfına odaklanarak yüksek doğruluk elde edebilir. PR eğrisi ise dengesiz veri kümelerinde modelin pozitif sınıfı ne kadar iyi tanıdığını daha doğru bir şekilde yansıtır.


PR eğrisinde yer alan iki temel özellik şunlardır:

- **Precision:** Modelin pozitif olarak sınıflandırdığı örnekler arasında gerçekten pozitif olanların oranıdır.
- **Recall:** Modelin, gerçek pozitif örnekler arasından ne kadarını doğru bir şekilde pozitif olarak sınıflandırdığına dair bir metriktir.

PR eğrisi, bu iki metriğin denge noktasını gösterir. Eğri altında kalan alan, modelin performansı hakkında bilgi verir; genellikle bu alan ne kadar büyükse, modelin pozitif sınıfa yönelik başarısı da o kadar yüksektir. PR eğrisinin eğimi, modelin belirli eşik değerlerinde precision ve recall arasında nasıl bir denge kurduğunu görmeyi sağlar. Örneğin, yüksek precision ve düşük recall bir model, yalnızca en emin olduğu tahminleri pozitif olarak sınıflandıracaktır, ancak bazı pozitif örnekleri kaçırabilir.

Özetle, PR eğrisi, bir modelin pozitif sınıfı tanıma yeteneğini daha hassas ve ayrıntılı bir şekilde incelemeyi sağlar ve özellikle dengesiz veri setlerinde model performansını değerlendirirken çok önemlidir.

6.4.1. Modelimizin Kesinlik-Duyarlılık Çıktısının Değerlendirmesi



Şekil 31 Kesinlik-Duyarlılık Eğrisi

Şekil 31’de gösterilen modelimizin PR-curve grafiğinde, "Crow" sınıfı için 0.931, "Eagle" için 0.919 ve "Owl" için 0.945 gibi yüksek ortalama precision değerleri elde edilmiş. Bu, modelin bu türler için yüksek doğruluk oranında tahminlerde bulunduğunu göstermektedir. Ancak, "Pigeon" sınıfı için precision değeri 0.727 gibi daha düşük bir oranda olup, bu sınıf için yapılan tahminlerin daha fazla hata içerdiğini ifade eder.

Grafikte yer alan tüm sınıflar için ortalama precision-recall değeri ise 0.875 olarak verilmiştir. Bu, genel olarak modelin tüm sınıfları kapsama ve doğru sınıflandırma konusunda başarılı bir performansa sahip olduğunu gösterir.

6.5. F1 Skoru ve Eğrisi

F1 skoru ve eğrisi, sınıflandırma modellerinin performansını ölçmek için yaygın olarak kullanılan metriklerdir. Özellikle dengesiz veri setlerinde etkili bir ölçüt sunarlar. Sınıflandırma modellerinin başarımını ölçmek için kullanılan metrikler arasında F1 Skoru, özellikle dengesiz veri setlerinde sıkça tercih edilen bir performans ölçütüdür. Bu metrik, sınıflandırıcının precision (kesinlik) ve recall (duyarlılık) değerleri arasında bir denge kurmayı amaçlayan bir yaklaşım sunar.

F1 skoru, precision ve recall değerlerinin harmonik ortalamasıdır ve aşağıdaki formül ile hesaplanır:

$$F1 = \frac{Precision \times Recall}{Precision + Recall}$$

F1 Skoru Denklemi

F1 eğrisi, bir modelin confidence threshold (güven eşik değeri) değiştikçe F1 skorunda meydana gelen değişimi görselleştiren bir grafikdir. Bu eğri, sınıflandırma performansını değerlendirmek ve optimum eşik değerini belirlemek için kritik bir analiz sunar.

F1 Eğrisinin Unsurları:

- Confidence Threshold (X Ekseni): Modelin bir sınıfı pozitif olarak tahmin etmesi için gerekli minimum güven seviyesi. Eşik değeri 0 ile 1 arasında değişir.
- F1 Skoru (Y Ekseni): Precision ve recall metriklerinin harmonik ortalaması. Modelin eşik değerine bağlı olarak ne kadar dengeli tahmin yaptığını ifade eder.


Eğri Üzerindeki Önemli Noktalar:

- Eğri, her eşik değerinde hesaplanan F1 skorlarını yansıtır.
- En yüksek F1 skorunun elde edildiği eşik değeri, modelin optimum performans sağladığı noktayı temsil eder.

F1 Eğrisinin Analizi: F1 eğrisi, modelin genel performansının yanı sıra eşik değeri seçiminde rehberlik eder.

- Eğrinin tepe noktası, modelin hem precision hem de recall arasında en iyi dengeyi sağladığı eşik değerini gösterir.
- Eğrinin şekli, modelin farklı eşik değerlerinde ne kadar duyarlı olduğunu yansıtır.

6.5.1. Modelimizin F1 Eğrisi Çıktısının Değerlendirmesi



Şekil 32 F1 eğrisi

- Genel Performans

Şekil 32’deki F1 skorunun 0.78 gibi yüksek bir maksimum değere ulaşması, modelimizin sınıflandırma görevinde oldukça iyi bir başarı gösterdiğini işaret ediyor. Bu, hem precision hem de recall arasında dengeli bir performans sağlandığını kanıtlıyor.

- Dengeli Performans

Şekil 32’deki kalın mavi çizginin genel seyri, modelin tüm sınıflar üzerinde oldukça tutarlı bir performans sunduğunu gösteriyor. Bu durum, modelinizin tek bir sınıfa odaklanmaktan ziyade, farklı sınıflar için dengeli bir başarıya sahip olduğunu ifade ediyor.

- Optimal Threshold Belirlenmesi

Şekil 32’deki F1 skorunun tepe noktasına ulaştığı eşik değerinin net bir şekilde belirlenmesi (0.449), modelin optimum performans sağlayacak şekilde ayarlanabildiğini gösteriyor. Bu durum, eşik değeri seçiminde modelin esnek olduğunu ve başarıyla optimize edilebildiğini gösteriyor.

- Güçlü Sınıf Performansı

Crow, Eagle, ve Falcon gibi sınıflarda F1 eğrilerinin oldukça yüksek ve tutarlı olması, modelin bazı sınıflar üzerinde özellikle güçlü bir performans sergilediğini işaret ediyor.

- Gelişim Potansiyeli


Şekil 32'deki F1 eğrisi genel olarak düzgün ve yükselen bir formda ilerliyor. Bu, modelin çeşitli eşik değerlerinde stabil çalışabildiğini ve daha ileri optimizasyonlarla çok daha iyi sonuçlar elde edilebileceğini gösteriyor.

6.6. Etiketler (Labels) ve Dağılımları

Bir derin öğrenme modelinin başarımı, eğitim sırasında kullanılan etiketlerin (labels) dağılımına ve özelliklerine doğrudan bağlıdır. Etiketler, eğitim veri setinde her örneğe karşılık gelen doğru sınıflandırma veya tahmin bilgilerini temsil eder. Modelin eğitimi sırasında, bu etiketler üzerinden öğrenme gerçekleştirilir. Şekil 33'te modelimizin etiket dağılımları çıktısı gösterilmiştir.


Labels Analizi:

- Etiket Sayısı ve Sınıf Dağılımı
 - a) Verilen veri setinde, her sınıfın kaç örnek ile temsil edildiğini ifade eder. Dengesiz bir dağılım, modelin az temsil edilen sınıflarda düşük performans göstermesine yol açabilir.
- Bounding Box Dağılımları
 - a) Nesne algılama modellerinde, etiketler sadece sınıf bilgisi değil, aynı zamanda bounding box (sınır kutusu) koordinatlarını içerir. Bu koordinatlar, bir nesnenin görüntü üzerindeki konumunu ve boyutunu temsil eder.
 - b) Bu dağılım, veri setindeki nesnelerin boyutları ve konumları hakkında önemli bilgiler sunar.



Şekil 33 Etiket dağılımı verileri

6.7. Modelin Genel Sonuçları ve Değerlendirilmesi



Şekil 34 Modelin genel sonuçları ve değerlendirilmesi

6.8. Kayıplar

6.8.1.Eğitim (Train) Kayıp Değerleri

- Train/box_loss
 - a) Modelin bounding box'ları (sınır kutuları) tahmin ederken yaptığı hatayı ifade eder. Kayıp değeri, doğruluk için optimize edilen bounding box regresyonundaki sapmayı temsil eder.
 - b) Değerlendirme: Bu kayıp, eğitim boyunca tutarlı bir şekilde azalıyor, bu da modelin bounding box tahminlerinde daha iyi hale geldiğini gösteriyor. Başlangıçta 1.4 civarında başlayan kayıp, son iterasyonlarda yaklaşık 0.8 seviyesine düşmüş.
- Train/cls_loss
 - a) Sınıflandırma kaybını (classification loss) ifade eder. Modelin, doğru sınıfları tahmin etmedeki başarısızlıklarını ölçer.
 - b) Değerlendirme: Bu kayıp başlangıçta yaklaşık 3.5 iken, eğitimin sonuna doğru 1'in altına düşüyor. Bu, modelin sınıflandırma konusunda giderek daha iyi hale geldiğini gösteriyor.
- Train/df_l_loss
 - a) Dağıtılmış odak kaybı (distributed focal loss), modelin bounding box sınırlarını daha hassas bir şekilde yerleştirme performansını ölçer.
 - b) Değerlendirme: Bu kayıp da sürekli azalarak modelin doğruluk kazandığını göstermektedir. 1.7 seviyesinden başlayan değer, eğitim sonunda 1.1 seviyesine inmiş.

6.8.2. Doğrulama (Validation) Kayıp Değerleri

- Val/box_loss
 - a) Eğitim setine paralel olarak doğrulama verisinde bounding box kaybını ifade eder.
 - b) Değerlendirme: Eğitim setine benzer bir azalma gözlemleniyor. Bu, modelin doğrulama verisinde de benzer bir performans gösterdiğini ve overfitting'in (aşırı öğrenme) az olduğunu işaret eder.
- Val/cls_loss
 - a) Doğrulama verisinde sınıflandırma kaybını ifade eder.
 - b) Değerlendirme: Eğitim kaybına paralel bir azalma sergiliyor, bu da modelin doğrulama setinde doğru sınıflandırma yapabildiğini gösteriyor.
- Val/df_l_loss
 - a) Doğrulama setinde bounding box sınırlarını hassas bir şekilde belirleme kaybını gösterir.
 - b) Değerlendirme: Eğitimle uyumlu bir düşüş sergiliyor. Bu, modelin genelleme yeteneğinin iyi olduğunu gösteriyor.

6.8.3. Performans Metrikleri

- Metrics/precision(B)
 - a) Modelin tahmin ettiği pozitif örneklerin ne kadarının gerçekten doğru olduğunu ölçer (kesinlik).
 - b) Değerlendirme: Eğitimin başında yaklaşık 0.3 olan precision değeri, son iterasyonlarda 0.8'in üzerine çıkıyor, bu da modelin doğru tahmin yapma yeteneğinin geliştiğini gösteriyor.
- Metrics/recall(B)
 - a) Modelin tüm doğru pozitifleri bulma kapasitesini ölçer (duyarlılık).
 - b) Değerlendirme: Recall değeri de 0.3 civarından başlayarak 0.75 seviyesine ulaşıyor. Model, doğru nesneleri yakalamada önemli bir ilerleme kaydetmiş.

- Metrics/mAP50(B)
 - a) Nesne algılama için kullanılan bir ölçüt olan mean Average Precision (ortalama doğruluk), Intersection over Union (IoU) eşik değerinde 0.50 olarak hesaplanır.
 - b) Değerlendirme: Eğitim sırasında mAP50 değeri sürekli artarak yaklaşık 0.85'e ulaşıyor, bu da modelin performansının oldukça iyi olduğunu gösteriyor.
- Metrics/mAP50-95(B)
 - a) Farklı IoU eşik değerleri (0.50'den 0.95'e kadar) üzerinden mAP'nin hesaplanması. Daha zorlu bir metrik olarak kabul edilir.
 - b) Değerlendirme: mAP50-95 değeri, eğitim sonunda 0.6 civarına ulaşıyor. Bu, modelin zorlu eşiklerde bile nispeten iyi bir performans gösterdiğini gösteriyor.

SONUÇ

Bu tezde havacılıkta kuş çarpmaları için alınan geleneksel yöntemlerle alınan önlemlerin yerine modern teknoloji ve yapay zeka kullanımı ile yeni bir yaklaşım amaçlanmıştır. YOLO mimarisi ile geliştirilen bu sistemin hedef nesneleri tespit etmekte oldukça başarılı sonuçlar verdiği görülmüştür. Kamera sistemlerinin hızla geliştiği modern dünyada verdiği etkili veriler sayesinde gelecek kuş tespit teknolojilerinin bu tezde işlenen görüntü analizi ve yapay zeka sistemleri ile yapılması kuvvetli muhtemeldir. Sistemin daha iyi optimize edilmesi ve etkili kameralar kullanımı ile gelecek olan bu yeni kuş tespit sistemi daha hafif, daha ucuz, daha az elektrik enerjisi harcayan ve etkili veriler verecektir. Neticede havacılık sektörünün güvenlik, ekonomi ve güvenilirlik alanlarının biraz daha gelişmesi söz konusudur. Yeni kuş algılama sistemi bakım, işletme açısından da daha verimli olacaktır. Bu tez kuş çarpmalarının havacılık sektörüne olan etkilerini azaltmaya yönelik yeni bir yaklaşım geliştirmeyi başarmıştır. Bu yaklaşım ile, mevcut radar tabanlı sistemlerin sınırlamalarını ortadan kaldırarak kuşları daha ayrıntılı bir şekilde tespit etmek ve uçuş güvenliğini artırmak için görüntü tabanlı bir kuş tanıma sistemi tasarlanmıştır. Mevcut radar sistemlerinin sınırlamalarını aşarak kuşları daha ayrıntılı bir şekilde tespit eden ve tanımlayan bir görüntü tabanlı kuş tanıma sistemi geliştirmiştir. Bu proje, kuş çarpmalarının önlenmesi ve havacılık güvenliğinin artırılması açısından büyük bir öneme sahiptir. YOLOv8 nesne tanıma modelini kullanarak kuşları tespit etmek ve türlerini belirlemek için bir görüntü tabanlı sistem geliştirmeyi içermektedir. YOLO modellerinin yeni ve daha etkililerinin gelmesi, yeni kamera sistemleri ve daha hızlı, yüksek işlem kapasiteli donanımlar ile birlikte sürekli gelişime açık bir uygulama olması düşünülmektedir.

KAYNAKLAR:

- [1] "What Computers Can't Do: The Limits of Artificial Intelligence" - Hubert Dreyfus
- [2] AI Topics - www.aitopics.org
- [3] "A Few Useful Things to Know About Machine Learning" - Pedro Domingos, Communications of the ACM
- [4] "Gradient-based Learning Applied to Document Recognition" - Yann Lecun, Léon Bottou, Yoshua Bengio, Patrick Haffner, Proceedings of the IEEE
- [5] "Understanding Machine Learning: From Theory to Algorithms" - Shai Shalev-Shwartz, Shai Ben-David
- [6] "Gradient-Based Learning Applied to Document Recognition" - Yann LeCun, Léon Bottou, Yoshua Bengio, Patrick Haffner
- [7] "Neural Networks and Deep Learning: A Textbook" - Charu C. Aggarwal
- [8] The original YOLO paper: "You Only Look Once: Unified, Real-Time Object Detection" by Joseph Redmon et al.
- [9] Comprehensive Review of YOLO Architectures: A review by Diana-Margarita Córdova-Esparza et al.
- [10] <https://medium.com/@busra.edgn/yolov8-ile-veri-seti-e%C4%9Fitimi-serisi-roboflow-c804f625adf3> (Eriřim Tarihi: 10.06.2024)
- [11] <https://ai.meta.com/tools/pytorch/> (Eriřim Tarihi: 08.07.2024)
- [12] <https://www.dhmi.gov.tr/Sayfalar/Haber/2023-yil-sonu-ucak-yolcu-ve-yuk-trafigi-aciklandi.aspx> (Eriřim Tarihi: 08.03.2024)
- [13] <https://viso.ai/deep-learning/yolov8-guide/> (Eriřim Tarihi: 08.03.2024)
- [14] <https://blog.roboflow.com/what-is-an-anchor-box/> (Eriřim Tarihi: 08.07.2024)
- [15] <https://blog.roboflow.com/what-is-yolov8/#what-is-yolov8> (Eriřim Tarihi: 08.07.2024)
- [16] <https://web.shgm.gov.tr/tr/kurumsal/1--tarihce> (Eriřim Tarihi: 08.03.2024)
- [17] <https://www.v7labs.com/blog/yolo-object-detection> (Eriřim Tarihi: 10.06.2024)
- [18] <https://ece-akdagli.medium.com/yolo-algoritmas%C4%B1-nedir-859862c7d5a6> (Eriřim Tarihi: 10.06.2024)
- [19] <https://medium.com/deep-learning-turkiye/yolo-algoritmas%C4%B1n%C4%B1-anlamak-290f2152808f> (Eriřim Tarihi: 10.06.2024)
- [20] <https://blog.roboflow.com/guide-to-yolo-models/> (Eriřim Tarihi: 08.07.2024)
- [21] <https://docs.ultralytics.com/tr/yolov5/> (Eriřim Tarihi: 10.06.2024)
- [22] <https://arc.aiaa.org/doi/abs/10.2514/1.C032008?journalCode=ja> (Eriřim Tarihi: 08.03.2024)
- [23] <https://www.sciencedirect.com/science/article/pii/S0266353810004926> (Eriřim Tarihi: 08.03.2024)